

## Pronađite redoslijed

- **Vremensko ograničenje:** 10 minuta
- **Okruženje:** jedan GPU ( $\approx 16$  GB VRAM), bez interneta
- **Veličina rješenja:** `solution.ipynb`  $\leq 1$  MB
- **Prostor za pohranu:** 5 GB

### Problem

Dati su vam govorni dijalozi na engleskom jeziku između dva učesnika, *Govornika A* i *Govornika B*. Svaki dijalog podijeljen je na replike govornika, pri čemu svaka replika sadrži govor samo jednog govornika. Svaka replika pohranjena je kao zasebna `.wav` audiodatoteka, tako da je cijeli dijalog predstavljen skupom `.wav` datoteka, po jednom za svaku repliku.

Nažalost, replike su nasumično izmiješane, tako da razgovor više nema smisla. U nazivu datoteke `chunk_{k}.wav`,  $k$  označava  $k$ -ti segment u izmiješanom skupu, a ne  $k$ -tu repliku u izvornom dijalogu.

**!! Vaš zadatak je rekonstruirati izvorni hronološki redoslijed razgovora.**



## Dataset

Svaki dijalog sadrži  $n$  audiodatoteka nazvanih `chunk_0.wav`, `chunk_1.wav`, ..., `chunk_{n-1}.wav`. Segmenti su pojedinačne replike. Nazivi datoteka odgovaraju samo izmiješanom redoslijedu. Oni ne ukazuju na to gdje segment pripada u izvornom razgovoru. Svaki dijalog ima 7–20 segmenata, mono, 44.1 kHz (možete promijeniti frekvenciju uzorkovanja).

**`prefix.json` sadrži indekse naziva datoteka prva dva segmenta u svakom dijalogu.** Time se određuje stvarni početak dijaloga i uklanja dvosmislenost između čitanja razgovora unaprijed ili unazad.

Naprimjer: 11: [7, 12] znači da su prva i druga replika dijaloga 11 redom `chunk_7.wav` i `chunk_12.wav`.

### Šta dobijate

Dobijate **dva direktorija u identičnom formatu:**

| Direktorij                        | Dijalozi | <code>answers.json</code> ? | Koristite ga za                                        |
|-----------------------------------|----------|-----------------------------|--------------------------------------------------------|
| <code>dataset/train/</code>       | 1,288    | ☐ uključeno                 | treniranje / fino podešavanje modela                   |
| <code>dataset/test_public/</code> | 100      | ☐ uključeno                 | pokretanje pipelinea i lokalno samostalno ocjenjivanje |

Tokom ocjenjivanja, vaš direktorij `dataset/test_public/` transparentno se zamjenjuje direktorijem `hidden evaluation set` (`test_leaderboard_a` za javnu rang-listu i `test_leaderboard_b` za konačnu rang-listu) — oni imaju istu veličinu i format kao `dataset/test_public/`, ali bez `answers.json`.

Vaš notebook ponovo se izvršava nad tim podacima, a datoteka `answers.json` koju proizvede koristi se za ocjenjivanje. Izdvojeni testni dijalozi dolaze iz iste distribucije kao `train`, tako da je vaš lokalni rezultat `test_public` vjerodostojan pokazatelj.

## Struktura direktorija

```
dataset/train/
  prefix.json  # {dialogue_id: [first_idx, second_idx]} filename index
  answers.json # {dialogue_id: P}  ground-truth order (rank convention)
  /
    chunk_0.wav
    ...
    chunk_{n-1}.wav

dataset/test_public/
  prefix.json
  answers.json      # present only in the development copy
  /
    chunk_0.wav
    ...
    chunk_{n-1}.wav
```

## Izlaz

Za svaki dijalog odredite izvorni hronološki redoslijed njegovih audiosegmenata. Vaše predviđanje treba biti permutacija  $P$  od  $\{0, 1, \dots, n-1\}$ , gdje je  $P[i]$  predviđena hronološka pozicija za `chunk_i.wav` ( $0 = \text{prvo}$ ).

Vaša izlazna datoteka `answers.json` treba preslikati svaki ID dijaloga na njegovu predviđenu permutaciju:

```
{
  "17": [2, 0, 1],
  "42": [0, 1],
  "108": [3, 1, 0, 4, 2, 5]
}
```

## Primjer

Dijalog ima 3 izmiješana segmenta `chunk_0`, `chunk_1`, `chunk_2`:

| izmiješani segment | izgovoreni sadržaj                                | stvarna pozicija (rang) |
|--------------------|---------------------------------------------------|-------------------------|
| chunk_0.wav        | „Nema problema — poslije ću ti poslati bilješke.“ | 2 (posljednje)          |
| chunk_1.wav        | „Hej, dolaziš li na sastanak u tri sata?“         | 0 (prvo)                |
| chunk_2.wav        | „Ne mogu — tada imam termin kod zubara.“          | 1                       |

Stvarni redoslijed je **chunk\_1** → **chunk\_2** → **chunk\_0**, pa je  $P = [2, 0, 1]$ , a `prefix.json` sadrži `[1, 2]`.

⚠ **P mora biti ispravna permutacija:** dužine  $n$ , indeksirana od 0, sa svakom vrijednošću tačno jednom. Duplikati, nedostajuće vrijednosti ili vrijednosti izvan raspona (npr. indeksiranje od 1) donose 0 bodova za taj dijalog, kao i dijalog koji nedostaje u datoteci. Neispravna datoteka ili datoteka koja nije u JSON formatu bit će odbijena.

## Bodovanje

Za bodovanje ovog zadatka koristi se **tačnost redoslijeda parova**. Provjerava se svaki par segmenata i postavlja pitanje: *koji od njih treba doći prvi?* Par je tačan ako vaše predviđanje daje isti odgovor kao referentni redoslijed. Za dijalog sa  $n$  segmenata postoji

$$M = n(n - 1)/2$$

parova; neka je  $I$  broj inverzija — parova poredanih drugačije od referentnog redoslijeda:

$$\text{score} = 1 - \frac{I}{M} \in [0, 1]$$

i **Konačni rezultat je prosjek rezultata po dijalogu za sve dijaloge u podjeli.**

## Dozvoljeni modeli

Za rješavanje ovog zadatka možete koristiti samo sljedeće prethodno trenirane modele, i tokom treniranja i tokom evaluacije. Svi ovi modeli već su preuzeti i dostupni u okruženju. Primjere njihove upotrebe možete vidjeti u baseline notebooku `solution.ipynb`. Imajte na umu da ne možete koristiti nijedan drugi model i da vaš program nema pristup internetu.

- **Reprezentacije govora: wav2vec 2.0. Whisper encoder** također se može koristiti kao ekstraktor obilježja. [kartica modela wav2vec](#)
- **Automatsko prepoznavanje govora (ASR): OpenAI Whisper** (bilo koje veličine). [kartica modela Whisper](#)
- **Jezički model: Qwen2.5-0.5B**, koji se može koristiti u zero-shot režimu ili fino podesiti na dostavljenoj podjeli `train`. [kartica modela Qwen](#) Imajte na umu da ograničenje od 10

minuta mora obuhvatiti svako treniranje ili fino podešavanje koje obavljate tokom ocjenjivanja, kao i inferenciju na evaluacijskom skupu.

## Kako predati rješenje

- Otvorite `solution.ipynb` i pokrenite sve ćelije. Potvrdite da zapisuje `answers.json` u radni direktorij s permutacijom za svaki dijalog u `dataset/test_public/` (100 dijaloga). Tokom ocjenjivanja notebook se ponovo pokreće na skrivenom testnom skupu, a `answers.json` koji tamo proizvede koristi se za ocjenjivanje.
- Poboljšajte rješenje ako želite — ili nemojte; sam baseline potvrđuje ispravnost pipelinea.
- Otvorite karticu Git na lijevoj bočnoj traci u JupyterLabu.
- **Dodajte u pripremno područje** `solution.ipynb` (ikona + pored njega).
- Unesite poruku commita i kliknite **Commit**.
- Kliknite oblak sa strelicom prema gore da izvršite push.
- Vratite se na ovu stranicu takmičenja i kliknite **Submit**.

Predajte tačno jednu datoteku, nazvanu `solution.ipynb`.