

Намерете реда

- **Ограничение за време:** 10 минути
- **Среда:** едно GPU (≈ 16 GB VRAM), без интернет
- **Размер на решението:** `solution.ipynb` ≤ 1 MB
- **Място за съхранение:** 5 GB

Задача

Дадени са Ви устни диалози на английски език между двама участници, *говорещ А* и *говорещ В*. Всеки диалог е разделен на реплики, като всяка реплика съдържа реч само на един говорещ. Всяка реплика се съхранява като отделен `.wav` аудиофайл, така че един пълен диалог е представен чрез множество от `.wav` файлове, по един за всяка реплика.

За съжаление, репликите са разбъркани в случаен ред, така че разговорът вече няма смисъл. В името на файла `chunk_{k}.wav`, k се отнася за k -тия фрагмент в разбърканото множество, а не за k -тата реплика в оригиналния диалог.

!! Вашата задача е да възстановите оригиналния хронологичен ред на разговора.



Набор от данни

Всеки диалог съдържа n аудиофайла с имена `chunk_0.wav`, `chunk_1.wav`, ..., `chunk_{n-1}.wav`. Фрагментите представляват отделни реплики. Имената на файловете съответстват единствено на разбъркания ред. Те не указват къде принадлежи даден фрагмент в оригиналния разговор. Всеки диалог има 7–20 фрагмента, моно, 44.1 kHz (можете да промените честотата на дискретизация).

`prefix.json` съдържа индексите от имената на файловете на първите два фрагмента във всеки диалог. Това идентифицира действителното начало на диалога и премахва нееднозначността между прочитането на разговора напред или назад.

Например: 11: [7, 12] означава, че първата и втората реплика на диалог 11 са съответно `chunk_7.wav` и `chunk_12.wav`.

Какво получавате

Получавате **две папки с еднакъв формат**:

Папка	Диалози	<code>answers.json</code> ?	Използвайте я, за да
<code>dataset/train/</code>	1,288	☒ включен	обучите/дообучите модела си
<code>dataset/test_public/</code>	100	☐ включен	изпълните своя pipeline и локално да изчислите резултата си

По време на оценяването, Вашата папка `dataset/test_public/` прозрачно се заменя с `hidden evaluation set` (`test_leaderboard_a` за публичната класация и `test_leaderboard_b` за финалната класация) — те имат същия размер и формат като `dataset/test_public/`, но без `answers.json`.

Вашият notebook се изпълнява отново върху тези данни и производеният от него файл `answers.json` се използва за оценяване. Заделените тестови диалози са от същото разпределение като `train`, така че Вашият локален резултат за `test_public` е надеждна предварителна оценка.

Структура на директориите

```
dataset/train/
  prefix.json # {dialogue_id: [first_idx, second_idx]} filename index
  answers.json # {dialogue_id: P} ground-truth order (rank convention)
  /
    chunk_0.wav
    ...
    chunk_{n-1}.wav

dataset/test_public/
  prefix.json
  answers.json # present only in the development copy
  /
    chunk_0.wav
    ...
    chunk_{n-1}.wav
```

Изход

За всеки диалог определете оригиналния хронологичен ред на неговите аудиофрагменти. Вашето предсказание трябва да бъде пермутация P на $\{0, 1, \dots, n-1\}$, където $P[i]$ е предсказаната хронологична позиция на `chunk_i.wav` (0 = първи).

Вашият изходен файл `answers.json` трябва да съпоставя всеки идентификатор на диалог с предсказаната му пермутация:

```
{
  "17": [2, 0, 1],
  "42": [0, 1],
  "108": [3, 1, 0, 4, 2, 5]
}
```

Пример

Даден диалог има 3 разбъркани фрагмента `chunk_0`, `chunk_1`, `chunk_2`:

разбъркан фрагмент	изговорено съдържание	действителна позиция (ранг)
chunk_0.wav	„Няма проблем — след това ще Ви изпратя записките.“	2 (последен)
chunk_1.wav	„Здравейте, ще дойдете ли на срещата в три часа?“	0 (първи)
chunk_2.wav	„Не мога — тогава имам час при зъболекаря.“	1

Действителният ред е **chunk_1** → **chunk_2** → **chunk_0**, следователно $P = [2, 0, 1]$, а `prefix.json` съдържа `[1, 2]`.

⚠ **P трябва да бъде валидна пермутация:** с дължина n , индексирана от 0, като всяка стойност присъства точно веднъж. Дублирани, липсващи или извън допустимия диапазон стойности (например индексирани от 1) носят резултат 0 за съответния диалог, както и диалог, който липсва от файла. Файл с неправилен формат или файл, който не е JSON, се отхвърля.

Оценяване

Метриката за оценяване на тази задача е **точност на подреждането по двойки**. Тя проверява всяка двойка фрагменти и задава въпроса: *кой от двата трябва да бъде първи?* Дадена двойка е правилна, ако Вашето предсказание дава същия отговор като истинското подреждане. За диалог с n фрагмента има

$$M = n(n - 1)/2$$

двойки; нека I е броят на инверсиите — двойките, подредени различно от еталонното подреждане:

$$\text{score} = 1 - \frac{I}{M} \in [0, 1]$$

! **Крайният резултат е средната стойност на резултатите за отделните диалози върху всички диалози в дела.**

Разрешени модели

Можете да използвате само следните предварително обучени модели за решаването на тази задача както по време на обучението, така и по време на оценяването. Всички тези модели вече са изтеглени и са налични в средата. Можете да видите примери за използването им в

базовия notebook `solution.ipynb`. Обърнете внимание, че не можете да използвате друг модел и програмата Ви няма достъп до интернет.

- **Представяния на реч: wav2vec 2.0. Whisper encoder** може също да се използва като екстрактор на признаци. [Карта на модела wav2vec](#)
- **Автоматично разпознаване на реч (ASR): OpenAI Whisper** (с произволен размер). [Карта на модела Whisper](#)
- **Езиков модел: Qwen2.5-0.5B**, който може да се използва или zero-shot, или дообучен върху предоставения дял `train`. [Карта на модела Qwen](#) Обърнете внимание, че ограничението от 10 минути трябва да обхваща всяко обучение или дообучаване, което извършвате по време на оценяването, както и предсказването върху набора за оценяване.

Как да предадете решението

- Отворете `solution.ipynb` и изпълнете всички клетки. Потвърдете, че той записва `answers.json` в работната директория с пермутация за всеки диалог в `dataset/test_public/` (100 диалога). По време на оценяването тетрадката се изпълнява отново върху скрития тестов набор и производеният там файл `answers.json` се оценява.
- Подобрете решението, ако желаете — или не го правете; само базовото решение е достатъчно, за да потвърди работата на pipeline.
- Отворете раздела Git в лявата странична лента на JupyterLab.
- Извършете **Stage** на `solution.ipynb` (иконата + до него).
- Въведете съобщение за commit и щракнете върху **Commit**.
- Щракнете върху облака със стрелка нагоре, за да извършите push.
- Върнете се на тази страница на състезанието и щракнете върху **Submit**.

Предайте точно един файл с име `solution.ipynb`.