

Potjera robota


- **Vremensko ograničenje:** 5 minutes
- **Okruženje:** jedan GPU (≈ 16 GB VRAM), bez interneta
- **Veličina rješenja:** `solution.ipynb` ≤ 1 MB
- **Prostor za pohranu:** 5 GB

Zadatak

Postoji šest robota. Svaki robot djeluje u maloj prostoriji predstavljenoj mrežom. Svaka prostorija ima 6×6 područje za igru okruženo zidovima, tako da puni `image` niz ima veličinu 8×8 (područje za igru + zidovi).

Svaki robot dobija instrukciju na engleskom jeziku koja opisuje zadatak. Snimak stanja može biti napravljen u bilo kojem trenutku dok ga robot izvršava. Vaš cilj je predvidjeti sljedeću akciju robota.

Roboti ne slijede uvijek najkraći put. Robot 0 može se ponašati drugačije od Robota 1, ali svaki robot slijedi vlastiti dosljedan obrazac. Koristite primjere za treniranje, koji uključuju tačne sljedeće akcije, kako biste naučili te obrasce.



Postoje tri vrste misija:

- **otići do** predmeta, na primjer "approach the red ball";
- **pokupiti** predmet, na primjer "grab the blue key";
- **staviti jedan predmet pored drugog**, na primjer "place the red box beside the green ball".

Ista instrukcija može biti napisana na nekoliko načina. Testni skup može sadržavati nove kombinacije poznatih izraza, boja i vrsta predmeta. Međutim, svaka riječ, obrazac izraza, boja, vrsta predmeta i vrsta misije korištena u testnom skupu također se pojavljuje u skupu za treniranje.

Svaki uzorak ima sljedeća polja:

Polje	Značenje
robot_id	koji je ovo od 6 robota (0–5)
image	prostorija, $8 \times 8 \times 2$ cjelobrojni niz u kojem kanal 0 sadrži kategorički object_idx (npr. 1=prazno, 2=zid, 10=robot), a kanal 1 sadrži kategorički colour_idx (0–5).
direction	smjer u kojem je robot trenutno okrenut
mission	vidljiva instrukcija na prirodnom jeziku

Polje	Značenje
carrying	null ili [object_idx, colour_idx] za predmet koji robot nosi

Redovi su nezavisni snimci stanja poredani nasumičnim redoslijedom. Oni ne čine epizode i tokom evaluacije nije dostupno nijedno prethodno opažanje niti akcija.

Dostavljeni `visualize_dataset.ipynb` omogućava vam da pregledate opažanja dostupna modelu u različitim situacijama.

Kodiranje mreže

`image[row][column] = [object_idx, colour_idx]`. Prvi indeks predstavlja red odozgo prema dolje, a drugi kolonu slijeva nadesno. Niz uključuje vanjski rub od zidova, pa je unutrašnjost kojom se može kretati 6×6 .

ID-jevi predmeta:

id	predmet
1	prazno polje
2	zid
5	ključ
6	lopta
7	kutija
10	robot
11	token

Tokeni se mogu pojaviti u prostorijski, ali se nikada ne navode u misijama.

ID-jevi boja su 0 crvena, 1 zelena, 2 plava, 3 ljubičasta, 4 žuta i 5 siva. Kanal boje nema značenje za prazna polja i zidove.

Slika ima samo dva prethodno navedena kanala. Smjer robota naveden je jednom, u polju `direction` najvišeg nivoa; nije dupliciran unutar `image`.

Akcije

Za kodove 0–3, akcije kretanja koriste sljedeće apsolutno mapiranje:

akcija	značenje
0	pomjeri se gore
1	pomjeri se dolje
2	pomjeri se lijevo
3	pomjeri se desno
4	pokupi
5	odloži

Polje `direction` označava trenutnu orijentaciju koristeći: 0 = Gore ($\text{red} - 1$), 1 = Dolje ($\text{red} + 1$), 2 = Lijevo ($\text{kolona} - 1$), 3 = Desno ($\text{kolona} + 1$).

Akcija kretanja prvo okreće robota u taj apsolutni smjer, a zatim ga pokušava pomjeriti za jedno polje. Zid ili predmet može blokirati kretanje, ali se smjer ipak mijenja. `pick up` i `drop` djeluju isključivo na susjedno ciljno polje određeno smjerom (npr. ako je `direction=0`, djeluje na ($\text{red} - 1$, kolona)).

Dataset

Dobijate dvije fascikle:

Fascikla	Redovi	<code>labels.json</code> ?	Koristite je za
<code>dataset/train/</code>	60,000	uključeno	treniranje modela
<code>dataset/test_public/</code>	3,600	uključeno u razvojnu kopiju	pokretanje i samostalno ocjenjivanje vašeg pipelinea

Svaka fascikla sadrži `observations.json`, JSON listu prethodno opisanih uzoraka. `labels.json` je poravnata JSON lista akcija (0–5).

Skup za treniranje sadrži tačno 10,000 redova po robotu i 20,000 redova iz svake porodice zadataka. Javni test sadrži 600 redova po robotu. Obuhvatite `image` funkcijom `numpy.asarray(...)` ako vam je potreban niz.

U vrijeme ocjenjivanja, `dataset/test_public/` se transparentno zamjenjuje skrivenim skupom od 3,600 opažanja u istom formatu, ali bez `labels.json`. Javna rang-lista koristi `test_leaderboard_a`; konačni poredak koristi `test_leaderboard_b`. Notebook koji bezuslovno čita oznake testa neće uspjeti. Čitajte oznake samo iz `dataset/train/`.

Izlaz

Zapišite `predictions.json` u radni direktorij notebooka. To mora biti JSON lista koja sadrži jednu cjelobrojnu akciju (0–5) po redu `dataset/test_public/observations.json`, istim redoslijedom. Za hipotetički testni skup koji sadrži šest uzoraka, ispravan izlaz bio bi:

```
[0, 3, 2, 2, 5, 4]
```

Nedostajuća ili neispravna JSON datoteka, pogrešan broj predikcija, vrijednost koja nije cijeli broj ili akcija izvan `{0, 1, 2, 3, 4, 5}` odbacuje se bez dodjele rezultata.

Bodovanje

Bodovanje predstavlja **srednju tačnost po robotu** na skali 0–100. Tačnost se prvo izračunava nezavisno za svakog robota, a zatim se uzima prosjek za svih šest robota. Stoga svaki robot ima jednaku težinu.

Kako predati rješenje

1. Otvorite `solution.ipynb` i pokrenite sve ćelije.
2. Potvrdite da zapisuje `predictions.json` sa 3,600 predikcija za javni testni skup.
3. Poboljšajte model ako želite; dostavljeni baseline samo demonstrira zahtijevani format ulaza i izlaza.
4. U Git kartici JupyterLaba označite `solution.ipynb` za commit i napravite commit, a zatim ga pošaljite.
5. Vratite se na stranicu takmičenja i kliknite **Predaj**.

Predajte tačno jednu datoteku nazvanu `solution.ipynb`.