

Δίλημμα Διπλού Πράκτορα

- **Χρονικό όριο:** 12 λεπτά.
- **Αποθηκευτικός χώρος:** 5 GB
- **Περιβάλλον:** μία GPU (≈ 16 GB VRAM), χωρίς διαδίκτυο
- **Μέγεθος λύσης:** `solution.ipynb` ≤ 1 MB
- **Βαθμολογία baseline:** 0

Στο εθνικό κέντρο τεχνητής νοημοσύνης στην Astana, δύο υπολογιστικά μοντέλα —το Model R (ένα ResNet-18) και το Model V (ένα ViT-Tiny)— αναλύουν φωτογραφίες. Αυτή τη στιγμή, και τα δύο μοντέλα εκτελούν τέλεια την εργασία τους, επιτυγχάνοντας ακρίβεια 100% και συμφωνώντας σε κάθε εικόνα. Για να ελέγξει πόσο διαφορετικοί είναι πραγματικά οι έξυπνοι «εγκέφαλοί» τους, ο επικεφαλής επιστήμονας σάς θέτει μια πρόκληση: να κάνετε μικροσκοπικές, σχεδόν αόρατες αλλαγές στα pixel κάθε φωτογραφίας, έτσι ώστε το Model R και το Model V να διαφωνούν πλήρως.



1. Εργασία

Δύο προεκπαιδευμένοι ταξινομητές εικόνων εξετάζουν την ίδια εικόνα. Στις εικόνες που παρέχονται σε αυτή την εργασία, και οι δύο ταξινομητές επιτυγχάνουν ακρίβεια 100%.

- **Model R:** `torchvision.models.resnet18` (ένα CNN, ResNet18).
- **Model V:** το `vit_tiny_patch16_224` του `timm` (ένα Transformer, ViT-Tiny).

Η εργασία σας είναι να δημιουργήσετε μια μικρή αλλαγή («διαταραχή») για κάθε εικόνα, έτσι ώστε τα δύο μοντέλα να διαφωνούν. Για κάθε εικόνα, πρέπει να δημιουργήσετε **δύο διαφορετικές** διαταραχές:

- **Τύπος A:** μετά την προσθήκη της, το Model R εξακολουθεί να ταξινομεί σωστά την εικόνα, αλλά το Model V την ταξινομεί εσφαλμένα.
- **Τύπος B:** μετά την προσθήκη της, το Model V εξακολουθεί να ταξινομεί σωστά την εικόνα, αλλά το Model R την ταξινομεί εσφαλμένα.

Κάθε διαταραχή πρέπει να είναι αρκετά *μικρή*, ώστε να είναι δύσκολο να γίνει αντιληπτή. Οι μικρότερες διαταραχές λαμβάνουν υψηλότερη βαθμολογία (βλ. Ενότητα 5). Η διαταραχή εφαρμόζεται απευθείας στην αρχική εικόνα, σε επίπεδο pixel.

2. Δημόσια δεδομένα

Μαζί με την εργασία παρέχεται ένα σύνολο εικόνων, οργανωμένο σε δύο διαχωρισμούς — `train` (100 εικόνες) και `test_public` (100 εικόνες) — καθένας από τους οποίους περιλαμβάνει εικόνες ποικίλης ανάλυσης. Όλες οι εικόνες προέρχονται από τις 1000 κλάσεις του ImageNet-1K και τόσο το Model R όσο και το Model V επιτυγχάνουν ακρίβεια 100% και στους δύο διαχωρισμούς.

Παρέχονται τα ακόλουθα αρχεία:

```
train/images/*.png      # 100 images in PNG format
train/labels.json       # maps each image index to its correct class
test_public/images/*.png # 100 images in PNG format
test_public/labels.json  # maps each image index to its correct class
```

Κατά τη βαθμολόγηση, ο φάκελός σας `dataset/test_public/` αντικαθίσταται με διαφανή τρόπο από δύο κρυφά σύνολα εικόνων (`test_leaderboard_a` και `test_leaderboard_b`) για την επίσημη βαθμολόγηση. Καθένα από αυτά περιέχει **100 εικόνες** σε μορφή PNG και ένα αρχείο ετικετών.

Σημείωση: Για αυτή την εργασία, οι ετικέτες στα **test datasets** είναι προσβάσιμες.

3. Μορφή εξόδου

Για κάθε εικόνα, πρέπει να παράγετε δύο αρχεία:

```
{index}_a.pt  # Type A perturbation
{index}_b.pt  # Type B perturbation
```

- Το `{index}` (0, 1, 2, ...), αντιστοιχεί στο όνομα της εικόνας στα datasets.

- Κάθε αρχείο είναι ένα μοναδικό tensor, αποθηκευμένο με `torch.save`. Το σχήμα του πρέπει να είναι $3 \times H \times W$, όπου τα H και W αντιστοιχούν στην **αρχική** ανάλυση αυτής της εικόνας (όχι 224×224).
- Ο κώδικας πρέπει να παράγει μόνο ένα αρχείο ZIP, το `submission.zip`. Τοποθετήστε όλα τα αρχεία `.pt` στο ανώτερο επίπεδο του αρχείου ZIP, χωρίς φάκελο που να τα περικλείει ή υποκαταλόγους.

```
submission.zip
├── 0_a.pt
├── 0_b.pt
├── 1_a.pt
└── ...
```

Το notebook θα σας ειδοποιήσει αν υπάρχει οποιαδήποτε προβλήματα με τη μορφή εξόδου.

4. Περιορισμοί


- **Μοντέλα:** Πρέπει να χρησιμοποιήσετε τα `torchvision.models.resnet18(pretrained=True)` και `timm.create_model('vit_tiny_patch16_224', pretrained=True)`. Δεν επιτρέπονται άλλα προεκπαιδευμένα μοντέλα.
- **Ακολουθία μετασχηματισμών (επιβάλλεται κατά την αξιολόγηση):** `Resize(256) → CenterCrop(224) → Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])`. See Section 3 of `baseline.ipynb` για λεπτομέρειες.
- **Ανάλυση διαταραχής:** Πρέπει να αντιστοιχεί στην **αρχική** ανάλυση της μη επεξεργασμένης εικόνας (όχι 224×224). Το tensor προστίθεται στη μη επεξεργασμένη εικόνα πριν από την ακολουθία μετασχηματισμών.
- **Μορφή εξόδου:** Μόνο αρχεία `.pt` — όχι PNG/JPG. Τα tensors προστίθενται στη μη επεξεργασμένη εικόνα και οι τιμές των pixel περικόπτονται στο `[0, 1]` πριν από την προεπεξεργασία.
- **Ονομασία αρχείων:** Επίπεδη λίστα, αυστηρή μορφή `{index}_a.pt / {index}_b.pt`. Δεν επιτρέπονται υποκατάλογοι μέσα στο zip.
- **Βιβλιοθήκες:** `torch`, `torchvision`, `timm`.

5. Βαθμολόγηση

Η τελική βαθμολογία υπολογίζεται ως εξής. Έστω M ο αριθμός των εικόνων στον διαχωρισμό, $Score_A$ ο αριθμός των επιτυχημένων διαταραχών Τύπου A και $Score_B$ ο αριθμός των επιτυχημένων διαταραχών Τύπου B:

$$S_{final} = \frac{Score_A + Score_B}{2M} \times PF$$

Η PF είναι μια συνάρτηση σχεδιασμένη ώστε να επιβάλλει ποινή σε διαταραχές με υψηλή νόρμα και να είναι πολύ ευαίσθητη κοντά στο ανώτατο όριο επίδοσης. Είναι φραγμένη στο εύρος από 0.5 έως 1. Η πλήρης υλοποίηση βρίσκεται στην Ενότητα 8 του `solution.ipynb`.



Σχήμα: Η καμπύλη της συνάρτησης ποινής.

6. Έλεγχος της Υποβολής

Στο notebook υπάρχουν έλεγχοι που σας ειδοποιούν αν υπάρχουν προβλήματα μορφοποίησης, στην Ενότητα 7 του notebook `solution.ipynb`.

7. Τοπική δοκιμή

Το `solution.ipynb` περιέχει ένα πλήρες, λειτουργικό παράδειγμα. Φορτώνει τα δημόσια δεδομένα, και τα δύο μοντέλα και τον επίσημο βαθμολογητή, και δημιουργεί ένα αρχείο ZIP υποβολής. Διαβάστε το πριν ξεκινήσετε.

8. Τρόπος υποβολής

- Αποθηκεύστε τις αλλαγές σας στο `solution.ipynb`.
- Ανοίξτε την καρτέλα Git στην αριστερή πλαϊνή γραμμή του JupyterLab.
- Κάντε **Stage** το `solution.ipynb` (το εικονίδιο + δίπλα του).
- Εισαγάγετε ένα μήνυμα commit και κάντε κλικ στο **Commit**.
- Κάντε κλικ στο σύννεφο με το βέλος προς τα επάνω για να εκτελέσετε push.
- Επιστρέψτε σε αυτή τη σελίδα του διαγωνισμού και κάντε κλικ στο **Submit**.

Υποβάλετε ακριβώς ένα αρχείο, με όνομα `solution.ipynb`.