

Fantazma e Makinerisë

- **Kufiri kohor:** 10 minuta
- **Rezultati bazë:** 28.6
- **Mjedisi:** një GPU (≈ 16 GB VRAM), pa internet
- **Madhësia e zgjidhjes:** `solution.ipynb` ≤ 20 MB
- **Hapësira e ruajtjes:** 5 GB
- **Modelet e paratrajuara:** vetëm [bge-base-en-v1.5](#) — një **enkoder** teksti (model embeddings).

Detyra

Gjëra të çuditshme po ndodhin në Arkivën Kombëtare të Kazakistanit. Bibliotekarët thonë se disa libra dikur përfundonin ndryshe, por askush nuk mund ta vërtetojë — çdo kopje është e njëjtë dhe çdo histori ende ka kuptim. Jeni ftuar si studiues i AI-it për të gjetur ndryshimet.



Një fragment fillon si tekst i shkruar nga një njeri dhe, në një pikë të caktuar, kalon në mënyrë të padukshme në një vazhdim të gjeneruar nga një model gjuhësor. I lexuar si një i tërë, ai duket si një pjesë koherente — por diku në mes autori ndryshon nga një person në një makinë. Detyra juaj është të **gjeni atë kalim: indeksin e karakterit ku përfundon pjesa njerëzore dhe fillon pjesa e makinës**.

Çdo kampion është një varg i vetëm `text`. Ekziston saktësisht një kufi. Gjithçka para tij është njerëzore; gjithçka prej tij e tutje është gjeneruar nga makina.

Dataset-i

Fragmente teksti në anglisht të thjeshtë, me nga një kufi secili.

- **Pjesa A** (para kufirit): një fragment nga një tekst i shkruar nga njeriu.
- **Pjesa B** (nga kufiri e tutje): një vazhdim i prodhuar nga një model gjuhësor, i kushtëzuar nga Pjesa A.
- Secila anë ka të paktën 180 fjalë; gjatësia totale është ~500–800 fjalë.
- **boundary_char_index** është offset-i i karakterit ku përfundon Pjesa A: `text[:boundary_char_index]` është pjesa njerëzore dhe `text[boundary_char_index:].lstrip()` është pjesa e makinës.

Çfarë merrni

Ju merrni **dy folder-a**:

Folder	Mostrat	answers.jsonl?	Përdoreni për të
dataset/train/	1,221	□ i përfshirë	trajnuar / fine-tune metodën tuaj
dataset/test_public/	380	□ i përfshirë (kopje dev)	ekzekutuar pipeline-in tuaj dhe llogaritur lokalisht rezultatin tuaj

Në kohën e vlerësimit, dosja juaj `dataset/test_public/` **zëvendësohet nga një bashkësi e fshehur vlerësimi**. Ajo ka të njëjtin format, por **pa answers.jsonl**. Notebook-u juaj ekzekutohet përsëri mbi të dhe vlerësohet `answers.jsonl` që ai prodhon.

- Tabela publike e renditjes përdor një bashkësi të fshehur **test_leaderboard_a** (380 mostra).
- Renditja përfundimtare përdor një bashkësi të fshehur **test_leaderboard_b** (380 mostra).

Të tria bashkësitë e vlerësimit kanë të njëjtën madhësi dhe janë marrë nga e njëjta shpërndarje si `train`, kështu që rezultati juaj lokal `dataset/test_public/` është një vlerësim i arsyeshëm i rezultatit tuaj në tabelën e renditjes.

Formati në disk

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- Id-të në `answers.jsonl` përputhen me id-të në `data.jsonl`.
- `dataset/train/` (me përgjigjet) është i disponueshëm sa herë që kryeni trajnim ose fine-tune.

Dalja (formati i dorëzimit)

Ju dorëzoni **një notebook të vetëm, i cili duhet të emërtohet solution.ipynb**. Ky emër i saktë skedari është i detyrueshëm. Çdo gjë tjetër refuzohet pa u ekzekutuar.

Notebook-u juaj duhet të **lexojë dataset/test_public/data.jsonl** dhe të shkruajë një skedar të vetëm **answers.jsonl** në rrënjën e repository-t — një objekt JSON për çdo rresht, që lidh çdo id kampioni me indeksin e parashikuar të karakterit të kufirit:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` duhet të jetë një **numër i plotë në $[0, \text{len}(\text{text})]$** .
- Çdo id në `dataset/test_public/data.jsonl` duhet të shfaqet saktësisht një herë. Një kampion që mungon nga `answers.jsonl` (ose me një vlerë jo të plotë / jashtë intervalit) merr rezultatin 0 për atë kampion.

Vlerësimi

Për çdo kampion, le të jetë p indeksi juaj i parashikuar dhe t kufiri i vërtetë. Rezultati për kampion bie në mënyrë eksponenciale me largësinë në karaktere:

$$\text{score} = \exp\left(-\frac{|p-t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Kjo sjell sjelljen e mëposhtme të rezultatit:

- **≈1.0** — karakteri i saktë i kufirit;
- **≈0.78** — devijim prej 25 karakteresh; - **≈0.61** — devijim prej 50 karakteresh;
- **≈0.37** — devijim prej 100 karakteresh;
- **≈0.01** — devijim prej 500 karakteresh.

Rezultati përfundimtar është mesatarja e rezultateve për kampion në të gjithë kampionët e ndarjes (raportohet në një shkallë 0–100). Metrika shpërblen afrimin, jo vetëm saktësinë.

Kufizimet

- **Mjedisi:** një GPU (≈16 GB VRAM), pa internet në kohën e vlerësimit — modeli i lejuar . **Koha reale: 10 minuta** për të gjithë ekzekutimin — ky duhet të mbulojë çdo trajnim / fine-tune që kryeni në kohën e vlerësimit **plus** inferencën në bashkësinë e vlerësimit.
- **Modeli i paratrajnuar i lejuar** — kjo listë është shteruese; nuk mund të përdoren pesha të tjera të paratrajnuara. Ai është **i siguruar paraprakisht në mjedis** (ngarkoheni normalisht, p.sh. `from_pretrained`; nuk ka internet në kohën e vlerësimit):
 - **bge-base-en-v1.5** — një **enkoder** teksti me 110M parametra (model embeddings). Ai prodhon embeddings fjalish/fragmentesh; nuk është një model gjuhësor gjenerues. Ju mund ta përdorni **siç është (veçori të ngrira) ose ta fine-tune në ndarjen train** (fine-tune i plotë përshtatet brenda buxhetit prej 16 GB / 10 minutash).
- Mjetet klasike / statistikore janë të pakufizuara: mund të ndërtoni çfarëdo modeli të bazuar në veçori (p.sh., klasifikues ose regresorë scikit-learn) mbi veçoritë embedding që llogaritni vetë. *Peshat e paratrajnuara të deep learning* kufizohen vetëm në listën e mësipërme.