

Մեքենայի ուրվականը

- Ժամանակի սահմանափակում. 10 րոպե
- **Baseline** միավոր. 28.6
- Միջավայր. մեկ GPU (≈ 16 ԳԲ VRAM), առանց ինտերնետի
- Լուծման չափը. `solution.ipynb` ≤ 20 ՄԲ
- Հիշողություն. 5 ԳԲ
- Նախազարգացված մոդելներ. միայն [bge-base-en-v1.5](#) — տեքստային **encoder** (embedding model):

Առաջադրանք

Ղազախստանի ազգային արխիվում տարօրինակ բաներ են տեղի ունենում: Գրադարանավարներն ասում են, որ որոշ գրքեր նախկինում այլ կերպ էին ավարտվում, բայց ոչ ոք չի կարող դա ապացուցել. յուրաքանչյուր օրինակ նույնն է, և յուրաքանչյուր պատմություն դեռևս իմաստալից է: Դուք, որպես ԱԻ (AI) հետազոտող, հրավիրված եք գտնելու այդ փոփոխությունները:



Տեքստի հատվածը սկսվում է որպես մարդու կողմից գրված տեքստ և, որոշակի պահի, անսկատորեն փոխարկվում է լեզվական մոդելի կողմից գեներացված շարունակության: Ամբողջությամբ կարդալիս այն թվում է մեկ կապակցված տեքստ, բայց ինչ-որ տեղ մեջտեղում հեղինակը մարդուց փոխվում է մեքենայի: Ձեր առաջադրանքն է գտնել այդ փոխարկումը. նիշի ինդեքսը, որտեղ ավարտվում է մարդկային մասը և սկսվում է մեքենայական մասը:

Յուրաքանչյուր նմուշ մեկ տող է՝ `text`: Այնտեղ կա ճիշտ մեկ սահման: Դրանից առաջ ամեն ինչ մարդու կողմից է, իսկ դրանից սկսած ամեն ինչ մեքենայի կողմից է գեներացված:

Dataset

Սովորական տեքստային (plain-text) անգլերեն հատվածներ, յուրաքանչյուրը՝ մեկ սահմանով:

- **Մաս A** (սահմանից առաջ). մարդու կողմից գրված տեքստ:
- **Մաս B** (սահմանից սկսած). լեզվական մոդելի կողմից ստեղծված շարունակություն՝ հիմնված Մաս A-ի վրա:
- Յուրաքանչյուր կողմն առնվազն 180 բառ է. ընդհանուր երկարությունը ~500–800 բառ է:
- **boundary_char_index**-ը նիշի շեղումն (character offset) է, որտեղ ավարտվում է Մաս A-ն. `text[:boundary_char_index]`-ը մարդկային մասն է, իսկ `text[boundary_char_index:].rstrip()`-ը՝ մեքենայական մասը:

Ինչ եք ստանում դուք

Դուք ստանում եք երկու թղթապանակ.

Թղթապանակ	Նմուշներ	answers.jsonl?	Օգտագործեք այն
dataset/train/	1,221	☐ Ներառված է	վարժեցնելու / fine-tune անելու ձեր մեթոդը
dataset/test_public/	380	☐ Ներառված է (dev պատճեն)	աշխատեցնելու ձեր pipeline-ը և տեղում ինքնազնահատվելու համար

Գնահատման պահին ձեր dataset/test_public/ թղթապանակը փոխարինվում է թաքնված գնահատման տվյալների բազմությամբ (evaluation set): Այն ունի նույն ձևաչափը, բայց առանց answers.jsonl-ի: Ձեր notebook-ը վերագործարկվում է դրա վրա, և դրա ստեղծած answers.jsonl-ը գնահատվում է:

- Հանրային leaderboard-ն օգտագործում է թաքնված **test_leaderboard_a** բազմությունը (380 նմուշ):
- Վերջնական վարկանիշային աղյուսակն օգտագործում է թաքնված **test_leaderboard_b** բազմությունը (380 նմուշ):

Բոլոր երեք գնահատման բազմությունները նույն չափի են և վերցված են նույն բաշխումից, ինչ train-ը, ուստի ձեր տեղական dataset/test_public/ միավորը ողջամիտ գնահատական է leaderboard-ի ձեր միավորի համար:

Սկավառակի վրա ձևաչափը

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl   # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl # dev copy only – ABSENT in the hidden grading set
```

- id-ները answers.jsonl-ում համապատասխանում են id-ներին data.jsonl-ում:
- dataset/train/-ը (պատասխաններով) հասանելի է ամեն անգամ, երբ դուք վարժեցնում կամ fine-tune եք անում:

Ելքային ձևաչափ (submission format)

Դուք ուղարկում եք մեկ **notebook**, որը պետք է անվանված լինի `solution.ipynb`: Ֆայլի հենց այս անվանումն է պահանջվում: Ցանկացած այլ բան մերժվում է՝ առանց աշխատեցվելու:

Ձեր notebook-ը պետք է կարդա `dataset/test_public/data.jsonl`-ը և գրի մեկ ֆայլ՝ `answers.jsonl`, ռեպրեզենտատիվ արմատային թղթապանակում — յուրաքանչյուր տողում մեկ JSON օբյեկտ, որը արտապատկերում է յուրաքանչյուր `sample id`-ն ձեր կանխատեսած սահմանային սիշի ինդեքսին:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index`-ը պետք է լինի ամբողջ թիվ $[0, \text{len}(\text{text})]$ միջակայքում:
- `dataset/test_public/data.jsonl`-ի յուրաքանչյուր `id` պետք է հանդիպի ճիշտ մեկ անգամ: `answers.jsonl`-ից բացակայող նմուշը (կամ ոչ ամբողջ թիվ / միջակայքից դուրս արժեք ունեցող) այդ նմուշի համար ստանում է 0 միավոր:

Գնահատում

Յուրաքանչյուր նմուշի համար ենթադրենք p -ը ձեր կանխատեսած ինդեքսն է, իսկ t -ը՝ իսկական սահմանը: Յուրաքանչյուր նմուշի միավորը նվազում է էքսպոնենցիալ կերպով՝ կախված նիշերի հեռավորությունից:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Սա հանգեցնում է միավորի հետևյալ վարքագծին:

- **=1.0** — սահմանի ճշգրիտ նիշ;
- **≈0.78** — 25 նիշի շեղում; **≈0.61** — 50 նիշի շեղում;
- **≈0.37** — 100 նիշի շեղում;
- **≈0.01** — 500 նիշի շեղում:

Վերջնական միավորը տվյալ բազմության բոլոր նմուշների ըստ-նմուշի միավորների **միջինն** է (ներկայացված 0-100 սանդղակով): Մետրիկան պարզևատրում է *մոտ* լինելու համար, ոչ միայն ճշգրիտ:

Սահմանափակումներ

- **Միջավայր.** մեկ GPU (≈16 ԳԲ VRAM), գնահատման պահին առանց ինտերնետի — թույլատրված մոդելը (ստորև) արդեն տրամադրված է: **Իրական ժամանակի (Wall-clock) բյուջե. 10 րոպե** ամբողջ աշխատանքի համար — սա պետք է ծածկի գնահատման պահին ձեր կատարած ցանկացած վարժեցում / fine-tuning **գումարած** ինֆերենսը (inference) գնահատման բազմության վրա:
- **Թույլատրված նախավարժեցված մոդել** — սա սպառիչ է, որևէ այլ նախավարժեցված կշիռներ (pretrained weights) չեն կարող օգտագործվել: Այն **նախապես տրամադրված է միջավայրում** (բեռնեք այն սովորական ձևով, օրինակ՝ `from_pretrained`, գնահատման պահին ինտերնետ չկա).
 - **bge-base-en-v1.5** — 110M-պարամետրով տեքստային **encoder** (embedding model): Այն ստեղծում է նախադասության/հատվածի embedding-ներ, այն գեներատիվ լեզվական մոդել չէ: Դուք կարող եք օգտագործել այն **ինչպես որ կա (սառնեցված հատկանիշներ)** կամ **fine-**

tune անել այն train բազմության վրա (ամբողջական fine-tuning-ը տեղավորվում է 16 ԳԲ / 10-րոպեանոց բյուջեի մեջ):

- Դասական / վիճակագրական գործիքներն անսահմանափակ են. դուք կարող եք կառուցել ցանկացած հատկանիշների վրա հիմնված (feature-based) մոդել (օրինակ՝ scikit-learn դասակարգիչներ կամ ռեգրեսորներ) ձեր իսկ հաշվարկած embedding հատկանիշների վրա: *Նախաձեռնարկված խորը ուսուցման (deep-learning) կշիռները* սահմանափակված են միայն վերը նշված ցանկով: