

Maşındakı Ruh

- **Vaxt limiti:** 10 dəqiqə
- **Baza balı:** 28.6
- **Mühit:** bir GPU (≈ 16 GB VRAM), internet yoxdur
- **Həllin ölçüsü:** `solution.ipynb` ≤ 20 MB
- **Yaddaş saxlanıcı:** 5 GB
- **Öncədən təlim edilmiş modellər:** yalnız [bge-base-en-v1.5](#) — mətn **enkoderi** (embedding modeli).

Tapşırıq

Qazaxıstan Milli Arxivində qəribə hadisələr baş verir. Kitabxanaçılar deyirlər ki, bəzi kitablar əvvəllər fərqli bitirdi, lakin heç kim bunu sübut edə bilmir — hər nüsxə eynidir və hər hekayə hələ də mənalı görünür. Siz bir AI tədqiqatçısı kimi dəyişiklikləri tapmaq üçün dəvət olunmusunuz.



Mətn parçası insan tərəfindən yazılmış mətn kimi başlayır və müəyyən bir məqamda səssizcə dil modeli tərəfindən yaradılmış davama keçir. Bütövlüklə oxunduqda, o, bir əlaqəli hissə kimi görünür — lakin ortada haradasa müəllif insandan maşına dəyişir. Sizin tapşırığınızı **həmin keçidi tapmaqdır: insan hissəsinin bitdiyi və maşın hissəsinin başladığı simvol indeksini**.

Hər nümunə tək bir `text` sətridir. Dəqiq bir sərhəd var. Ondən əvvəlki hər şey insana aiddir; ondən etibarən hər şey maşın tərəfindən yaradılmışdır.

Məlumat dəsti

İngiliscə mətn parçaları, hər birində bir sərhəd var.

- **A Hissəsi** (sərhəddən əvvəl): insan tərəfindən yazılmış mətnin parçası.
- **B Hissəsi** (sərhəddən etibarən): A Hissəsi əsasında dil modeli tərəfindən yaradılmış davam.
- Hər tərəf ən azı 180 sözdən ibarətdir; ümumi uzunluq ~500–800 sözdür.
- **boundary_char_index** B hissəsinin ilk simvol indeksidir: `text[boundary_char_index:]` maşın hissəsidir və `text[:boundary_char_index]` insan hissəsi və onu maşın hissəsindən ayıran boşluq olan parça.

Əldə etdikləriniz

Siz **iki qovluq** alırsınız:

Qovluq	Nümunələr	answers.jsonl?	Bunun üçün istifadə edin
dataset/train/	1,221	☐ daxildir	metodunuzu təlim etmək / incə tənzimləmək
dataset/test_public/	380	☐ daxildir (dev nüsxəsi)	piöpeline-ı işlətmək və lokal olaraq özünüzü qiymətləndirmək

Qiymətləndirmə vaxtı dataset/test_public/ qovluğunuz **gizli qiymətləndirmə dəsti ilə əvəz olunur**. O, eyni formata malikdir, lakin **answers.jsonl olmadan**. Noutbukunuz onun üzərində yenidən işlədilir və onun istehsal etdiyi answers.jsonl qiymətləndirilir.

- İctimai liderlər lövhəsi gizli **test_leaderboard_a** dəstindən (380 nümunə) istifadə edir.
- Yekun sıralama gizli **test_leaderboard_b** dəstindən (380 nümunə) istifadə edir.

Hər üç qiymətləndirmə dəsti eyni ölçüdədir və train ilə eyni paylanmadan götürülmüşdür, beləliklə, sizin lokal dataset/test_public/ balınız liderlər lövhəsi balınız üçün məntiqli bir təxmin olur.

Diskdəki format

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- answers.jsonl daxilindəki id-lər data.jsonl daxilindəki id-lərlə uyğun gəlir.
- dataset/train/ (cavablar olan) təlim keçdiyiniz və ya incə tənzimləmə etdiyiniz istənilən vaxt əlçatandır.

Çıxış (təqdimetmə formatı)

Siz **tək bir noutbuk təqdim edirsiniz və o, solution.ipynb adlandırılmalıdır**. Məhz bu fayl adı tələb olunur. Başqa hər şey işlədilmədən rədd edilir.

Noutbukunuz **dataset/test_public/data.jsonl faylını oxumalı** və repositorianın kökündə tək bir **answers.jsonl** faylı yazmalıdır — hər sətirdə bir JSON obyektı olmaqla, hər nümunə id-sini proqnozlaşdırdığınız sərhəd simvolu indeksinə uyğunlaşdırılmalıdır:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` `[0, len(text)]` daxilində tam ədəd olmalıdır.

- `dataset/test_public/data.jsonl` daxilindəki hər bir id dəqiq bir dəfə görünməlidir. `answers.jsonl` faylında çatışmayan (və ya tam ədəd olmayan / diapazondan kənar dəyəri olan) nümunə həmin nümunə üçün 0 bal alır.

Qiymətləndirmə

Hər bir nümunə üçün fərz edək ki, p sizin proqnozlaşdırdığınız indeks, t isə həqiqi sərhəddir. Nümunəbaşına bal simvol məsafəsi ilə eksponensial olaraq azalır:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Bu, balın aşağıdakı davranışına gətirib çıxarır:

- **≈1.0** — dəqiq sərhəd simvolu;
- **≈0.78** — 25 simvol kənar; - **≈0.61** — 50 simvol kənar;
- **≈0.37** — 100 simvol kənar;
- **≈0.01** — 500 simvol kənar.

Yekun bal bölmədəki bütün nümunələr üzrə nümunəbaşına balların **ortalamasıdır** (0–100 şkalasında bildirilir). Metrika yalnız dəqiq olmağı deyil, həm də *yaxınlaşmağı* mükafatlandırır.

Məhdudiyyətlər

- **Mühit:** bir GPU (≈16 GB VRAM), qiymətləndirmə zamanı internet yoxdur — icazə verilən model (aşağıda) artıq təmin edilib. **Ümumi vaxt büdcəsi: bütün icra üçün 10 dəqiqə** — bu, qiymətləndirmə zamanı etdiyiniz hər hansı təlim / incə tənzimləməni **üstəgəl** qiymətləndirmə dəstində çıxarışı (inference) əhatə etməlidir.
- **İcazə verilən öncədən təlim edilmiş model** — bu siyahı tamdır; başqa heç bir öncədən təlim edilmiş çəkildən istifadə edilə bilməz. O, **mühitdə öncədən təmin edilib** (adi qaydada yükləyin, məs. `from_pretrained`; qiymətləndirmə zamanı internet yoxdur):
 - **bge-base-en-v1.5** — 110M parametrik mətn **enkoderi** (embedding modeli). O, cümlə/mətn parçası embedding-ləri istehsal edir; o, generativ dil modeli deyildir. Siz ondan **olduğu kimi (dondurulmuş xüsusiyyətlər) istifadə edə və ya onu `train` bölməsində fine-tuning bilərsiniz** (tam fine-tuning 16 GB / 10 dəqiqəlik büdcəyə sığır).
- Klassik / statistik alətlər məhdudlaşdırılır: özünüz hesabladığınız embedding xüsusiyyətlərinin üstündə istənilən xüsusiyyət əsaslı modeli (məsələn, scikit-learn təsnifatlandırıcıları və ya reqressorları) qura bilərsiniz. *Öncədən təlim edilmiş dərin təlim çəkili* yalnız yuxarıdakı siyahı ilə məhdudlaşdırılır.