

Призракът в машината

- **Ограничение по време:** 10 минути
- **Резултат на базовото решение:** 28.6
- **Среда:** едно GPU (≈ 16 GB VRAM), без интернет
- **Размер на решението:** `solution.ipynb` ≤ 20 MB
- **Място за съхранение:** 5 GB
- **Предварително обучени модели:** само [bge-base-en-v1.5](#) — текстов **енкодер** (модел за ембединги).

Задача

В Националния архив на Казахстан се случват странни неща. Библиотекарите твърдят, че някои книги преди са завършвали по различен начин, но никой не може да го докаже — всички екземпляри са еднакви и всяка история все още има смисъл. Поканени сте като изследовател в областта на изкуствения интелект, за да откриете промените.



Откъс започва като текст, написан от човек, и в някакъв момент незабележимо преминава към продължение, генерирано от езиков модел. Прочетен като цяло, той изглежда като един свързан текст — но някъде по средата авторът се сменя от човек на машина. Вашата задача е да **намерите този преход: индекса на символа, при който човешката част завършва и машинната част започва.**

Всяка извадка е единичен низ `text`. Има точно една граница. Всичко преди нея е написано от човек; всичко от нея нататък е генерирано от машина.

Набор от данни

Английски текстови откъси в обикновен текст, всеки с по една граница.

- **Част А** (преди границата): откъс от текст, написан от човек.
- **Част В** (от границата нататък): продължение, създадено от езиков модел, обусловено от Част А.
- Всяка част съдържа поне 180 думи; общата дължина е ~500–800 думи.
- **boundary_char_index** е отместването в символи, при което Част А завършва: `text[:boundary_char_index]` е човешката част, а `text[boundary_char_index:].lstrip()` е машинната част.

Какво получавате

Получавате **две папки**:

Папка	Извадки	answers.jsonl?	Използвайте я за
dataset/train/	1,221	□ включено	обучение / дообучаване на Вашия метод
dataset/test_public/	380	□ включено (копие за разработка)	изпълнение на Вашия pipeline и локално самооценяване

По **време на оценяването** Вашата папка `dataset/test_public/` се **заменя със скрит набор за оценяване**. Той има същия формат, но е **без answers.jsonl**. Вашата тетрадка се изпълнява отново върху него и създаденият от него `answers.jsonl` се оценява.

- Публичната класация използва скрит набор **test_leaderboard_a** (380 извадки).
- Крайното класиране използва скрит набор **test_leaderboard_b** (380 извадки).

И трите набора за оценяване са с еднакъв размер и са извлечени от същото разпределение като `train`, така че Вашият локален резултат за `dataset/test_public/` е разумна оценка за резултата Ви в класацията.

Формат на диска

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only — ABSENT in the hidden grading set
```

- Идентификаторите в `answers.jsonl` съвпадат с идентификаторите в `data.jsonl`.
- `dataset/train/` (с отговорите) е наличен винаги когато обучавате или дообучавате.

Изход (формат за предаване)

Трябва да предадете **една тетрадка, която задължително трябва да бъде именувана solution.ipynb**. Изисква се точно това име на файла. Всичко друго се отхвърля, без да бъде изпълнено.

Вашата тетрадка трябва да **прочете dataset/test_public/data.jsonl** и да запише един файл **answers.jsonl** в основната директория на хранилището — по един JSON обект на ред, който съпоставя

идентификатора на всяка извадка с предвидения от Вас индекс на символа на границата:

```
{"id": "example_000123", "boundary_char_index": 1790}  
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` трябва да бъде **цяло число в $[0, \text{len}(\text{text})]$** .
- Всеки идентификатор в `dataset/test_public/data.jsonl` трябва да се среща точно веднъж. Извадка, която липсва в `answers.jsonl` (или е със стойност, която не е цяло число / е извън допустимия диапазон), получава резултат 0 за тази извадка.

Оценяване

За всяка извадка, нека p бъде предвиденият от Вас индекс, а t — действителната граница. Резултатът за извадката (per-sample score) намалява експоненциално с разстоянието в символи:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Това води до следното поведение на резултата:

- **=1.0** — точно върху символа на границата;
- **≈0.78** — отклонение от 25 символа; **≈0.61** — отклонение от 50 символа;
- **≈0.37** — отклонение от 100 символа;
- **≈0.01** — отклонение от 500 символа.

Крайният резултат е средната стойност на резултатите за отделните извадки върху всички извадки в дела (представена по скала 0–100). Метриката възнаграждава *близостта до границата*, а не само точното ѝ определяне.

Ограничения

- **Среда:** едно GPU (≈16 GB VRAM), без интернет по време на оценяването — разрешеният модел (по-долу) вече е предоставен. **Ограничение за общото реално време: 10 минути** за цялото изпълнение — то трябва да включва всяко обучение / дообучаване, което извършвате по време на оценяването, **както и** предсказването върху набора за оценяване.
- **Разрешен предварително обучен модел** — този списък е изчерпателен; не могат да се използват други предварително обучени тегла. Той е **предварително предоставен в средата** (заредете го по обичайния начин, напр. `from_pretrained`; по време на оценяването няма интернет):
 - **bge-base-en-v1.5** — текстов **енкодер** със 110M параметъра (модел за ембединги). Той създава ембединги на изречения/откъси; не е генеративен езиков модел. Можете да го използвате **без промени (със замразени признаци)** или **да го дообучите върху дела train** (пълното дообучаване се вмести в ограниченията от 16 GB / 10 минути).
- Класическите / статистическите инструменти не са ограничени: можете да създадете произволен модел, базиран на признаци (напр. класификатори или регресори от `scikit-learn`), върху ембединг признаци, които сами изчислите. Ограничението до горния списък се отнася само за *предварително обучените тегла на модели за дълбоко обучение*.