

机器幽灵

- 时间限制：10 分钟
- 基线分数：28.6
- 环境：一块 GPU (≈ 16 GB VRAM)，无互联网
- 提交文件大小 (Solution size): `solution.ipynb` ≤ 20 MB
- 存储空间：5 GB
- 预训练模型：仅限 [bge-base-en-v1.5](#)——一个文本编码器 (embedding 模型)。

任务

哈萨克斯坦国家档案馆正在发生一些怪事。图书管理员说，有些书过去的结局并非如此，但无人能够证明——每一本副本都一模一样，而且每个故事仍然合乎情理。现邀请你作为一名 AI 研究员找出这些改动。



一段文本起初是人类撰写的，并在某个位置悄然切换为由语言模型生成的续文。整体阅读时，它看起来像一篇连贯的文章——但在中间的某个位置，作者从人变成了机器。你的任务是找出这个切换位置：人类部分结束且机器部分开始处的字符索引 (the character index where the human part ends and the machine part begins)。

每个样本都是一个字符串 `text`。其中恰好有一个边界。边界之前的所有内容都由人类撰写；从边界开始的所有内容都由机器生成。

数据集

纯文本英语段落，每段各有一个边界。

- **A 部分** (边界之前)：人类撰写文本的节选。
- **B 部分** (从边界开始)：由语言模型在以 A 部分为条件的情况下生成的续文。

- 两部分各至少有 180 个单词；总长度约为 500–800 个单词。
- **boundary_char_index** is the index of the **first character of Part B**:
 - `text[:boundary_char_index]` 是人类部分 (`text[:boundary_char_index]` is the human part together with **the single space** that separates the two.), 而
 - `text[boundary_char_index:]` 是机器部分 (`text[boundary_char_index:]` is exactly the machine part)。

你将获得的内容

你会收到**两个文件夹**：

文件夹	样本数	answers.jsonl?	用途
dataset/train/	1,221	☒ 包含	训练／微调你的方法
dataset/test_public/	380	☒ 包含（开发集副本）	运行你的流程并在本地自行评分

在**评分时**，你的 `dataset/test_public/` 文件夹会被**替换为一个隐藏评测集**。它的格式相同，但**不含 answers.jsonl**。你的笔记本会在该数据集上重新运行，并对其生成的 `answers.jsonl` 进行评分。

- 公开排行榜使用隐藏的 **test_leaderboard_a** 数据集（380 个样本）。
- 最终排名使用隐藏的 **test_leaderboard_b** 数据集（380 个样本）。

这三个评测集的大小相同，并且都与 `train` 来自相同的分布，因此你在本地获得的 `dataset/test_public/` 分数可以合理估计你的排行榜分数。

磁盘格式

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only — ABSENT in the hidden grading set
```

- `answers.jsonl` 中的 `id` 与 `data.jsonl` 中的 `id` 相匹配。
- 每当你进行训练或微调时，都可使用 `dataset/train/`（含答案）。

输出（提交格式）

你需要提交**一个笔记本**，其名称必须为 **solution.ipynb**。必须使用这一确切文件名。任何其他名称的文件都会被拒绝，且不会运行。

你的笔记本必须**读取 dataset/test_public/data.jsonl**，并在仓库根目录下写入一个文件 **answers.jsonl**——每行一个 JSON 对象，将每个样本 `id` 映射到你预测的边界字符索引：

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` 必须是位于 `[0, len(text)]` 中的整数。
- `dataset/test_public/data.jsonl` 中的每个 `id` 都应恰好出现一次。若某个样本未出现在 `answers.jsonl` 中（或其值不是整数／超出范围）（**or with a non-integer / out-of-range value**），则该样本得分为 0。

评分

对于每个样本，令 p 为你预测的索引， t 为真实边界。单样本分数随字符距离呈指数衰减：

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

因此，分数具有以下表现：

- **=1.0**——与边界字符完全一致；
- **≈0.78**——偏差 25 个字符；**≈0.61**——偏差 50 个字符；
- **≈0.37**——偏差 100 个字符；
- **≈0.01**——偏差 500 个字符。

最终分数是该数据划分中所有样本的单样本分数平均值（以 0–100 的尺度报告）。该指标会奖励接近边界的预测，而不仅仅是完全准确的预测 (**rewards getting close, not just exact.**)。

约束

- **环境：**一块 GPU（≈16 GB VRAM），评分时无互联网——允许使用的模型（见下文）已预先提供。整个运行过程的**实际用时限制：10 分钟**——其中必须包括你在评分时进行的任何训练／微调，**以及在评测集上的推理**。
- **允许的预训练模型**——以下列表是完整列表；不得使用任何其他预训练权重。该模型已**预先提供在环境中**（正常加载即可，例如 `from_pretrained`；评分时无互联网）：
 - **bge-base-en-v1.5**——一个具有 110M 参数的文本**编码器**（embedding 模型）。它会生成句子／段落 embedding；它不是生成式语言模型 (**not a generative language model**)。你可以**直接使用它（冻结特征），也可以在 train 数据划分上对其进行微调**（全量微调可满足 16 GB／10 分钟的限制）。
- 对经典／统计模型不作限制：你可以在自行计算的 embedding 特征之上构建任何基于特征的模型（例如 scikit-learn 分类器或回归器）。*预训练深度学习权重受上述列表限制 (Pretrained deep-learning weights are only restricted to the list above.)*。