

Duch stroje

- **Časový limit:** 10 minut
- **Skóre baseline:** 28.6
- **Prostředí:** jedno GPU (≈16 GB VRAM), bez internetu
- **Velikost řešení:** `solution.ipynb` ≤ 20 MB
- **Úložiště:** 5 GB
- **Předtrénované modely:** pouze [bge-base-en-v1.5](#) — textový **enkodér** (model embeddingů).

Úloha

V Národním archivu Kazachstánu se dějí podivné věci. Knihovníci tvrdí, že některé knihy dříve končily jinak, ale nikdo to nedokáže prokázat — všechny výtisky jsou stejné a každý příběh stále dává smysl. Jako výzkumníci v oblasti AI jste přizváni, abyste změny lokalizovali.



Pasáž začíná jako text napsaný člověkem a v určitém okamžiku nepozorovaně přejde v pokračování vygenerované jazykovým modelem. Jako celek působí jako jeden souvislý text — ale někde uprostřed se autor změní z člověka na stroj. Vaším úkolem je **najít tento přechod: index znaku, na kterém lidská část končí a strojová část začíná**.

Každý vzorek je jeden řetězec `text`. Existuje právě jedna hranice. Vše před ní je lidské; vše od ní dále je vygenerované strojem.

Dataset

Anglické pasáže v prostém textu, každá s jednou hranicí.

- **Část A** (před hranicí): úryvek textu napsaného člověkem.
- **Část B** (od hranice dále): pokračování vytvořené jazykovým modelem, podmíněné částí A.
- Každá část má alespoň 180 slov; celková délka je ~500–800 slov.
- **boundary_char_index** je posun ve znacích, na kterém část A končí: `text[:boundary_char_index]` je lidská část a `text[boundary_char_index:].rstrip()` je strojová část.

Co dostanete

Obdržíte **dvě složky**:

Složka	Vzorky	answers.jsonl?	Použití
dataset/train/	1,221	☐ obsaženo	trénování / doladění vaší metody
dataset/test_public/	380	☐ obsaženo (vývojová kopie)	spuštění vaší pipeline a místní vyhodnocení vlastního skóre

Při **hodnocení** bude vaše složka `dataset/test_public/` **nahrazena skrytou evaluační sadou**. Má stejný formát, ale **bez answers.jsonl**. Váš notebook se na ní znovu spustí a `answers.jsonl`, který vytvoří, bude vyhodnocen.

- Veřejný žebříček používá skrytou sadu **test_leaderboard_a** (380 vzorků).
- Konečné pořadí používá skrytou sadu **test_leaderboard_b** (380 vzorků).

Všechny tři evaluační sady mají stejnou velikost a pocházejí ze stejného rozdělení jako `train`, takže vaše místní skóre `dataset/test_public/` je rozumným odhadem vašeho skóre v žebříčku.

Formát na disku

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- ID v `answers.jsonl` odpovídají ID v `data.jsonl`.
- `dataset/train/` (s odpověďmi) je k dispozici vždy, když trénujete nebo doladujete.

Výstup (formát odevzdání)

Odevzdáváte **jediný notebook, který musí být pojmenován solution.ipynb**. Tento přesný název souboru je povinný. Cokoli jiného bude odmítnuto bez spuštění.

Váš notebook musí **načíst dataset/test_public/data.jsonl** a zapsat jediný soubor **answers.jsonl** do kořenového adresáře repozitáře — jeden objekt JSON na řádek, který mapuje ID každého vzorku na vámi předpovězený index znaku hranice:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` musí být celé číslo v `[0, len(text)]`.

- Každé ID v `dataset/test_public/data.jsonl` by se mělo objevit právě jednou. Vzorek, který chybí v `answers.jsonl` (nebo má neceločíselnou / mimo rozsah ležící hodnotu), získá za tento vzorek skóre 0.

Hodnocení

Pro každý vzorek nechť p je vámi předpovězený index a t je skutečná hranice. Skóre za vzorek exponenciálně klesá se vzdáleností ve znacích:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

To vede k následujícímu chování skóre:

- **≈1.0** — přesný znak hranice;
- **≈0.78** — odchylka 25 znaků; **≈0.61** — odchylka 50 znaků;
- **≈0.37** — odchylka 100 znaků;
- **≈0.01** — odchylka 500 znaků.

Konečné skóre je průměrem skóre za jednotlivé vzorky přes všechny vzorky v dané části (uváděným na škále 0–100). Metrika odměňuje přiblížení se, nejen přesnost.

Omezení

- **Prostředí:** jedno GPU (≈16 GB VRAM), při hodnocení bez internetu — povolený model (níže) je již poskytnut. **Limit reálného času: 10 minut** pro celý běh — ten musí zahrnovat veškeré trénování / doladování prováděné při hodnocení i inferenci na evaluační sadě.
- **Povolený předtrénovaný model** — tento seznam je úplný; žádné jiné předtrénované váhy nesmějí být použity. Model je **předem poskytnut v prostředí** (načtete jej běžným způsobem, např. `from_pretrained`; při hodnocení není k dispozici internet):
 - **bge-base-en-v1.5** — textový **enkodér** se 110M parametry (model embeddingů). Vytváří embeddingy vět/pasáží; není to generativní jazykový model. Můžete jej použít **tak, jak je (se zmrazenými příznaky), nebo jej doladit na části train** (úplné doladění se vejde do limitu 16 GB / 10 minut).
- Klasické / statistické nástroje nejsou omezeny: nad příznaky embeddingů, které si sami vypočítáte, můžete vytvořit libovolný model založený na příznacích (např. klasifikátory nebo regresory scikit-learn). *Předtrénované váhy hlubokého učení* jsou omezeny pouze na výše uvedený seznam.