

የማሽኑ መንፈስ

- የጊዜ ገደብ:- 10 ደቂቃዎች
- የመነሻ ነጥብ:- 28.6
- አካባቢ:- አንድ GPU (≈ 16 GB VRAM)፣ ኢንተርኔት የለም
- የመፍትሔ መጠን:- `solution.ipynb` ≤ 20 MB
- ማከማቻ:- 5 GB
- ቀድመው የሰለጠነ ሞዴሎች:- [bge-base-en-v1.5](#) ብቻ — የጽሑፍ **encoder** (embedding model)።

ተግባር

በካዛክስታን ብሔራዊ መዝገብ ቤት አንግዳ ነገሮች እየተከሰቱ ነው። የቤተ መጻሕፍት ሠራተኞች አንዳንድ መጻሕፍት ቀደም ሲል በተለየ ሁኔታ ይጠናቀቁ እንደነበር ይናገራሉ፤ ነገር ግን ማንም ማረጋገጥ አይችልም — እያንዳንዱ ቅጂ ተመሳሳይ ነው፣ እና እያንዳንዱ ታሪክ አሁንም ትርጉም ይሰጣል። ለውጦቹን እንዲያገኙ እንደ AI ተመራማሪ ተጋብዘዋል።



አንድ ምንጣብ በሰው የተጻፈ ጽሑፍ ሆኖ ይጀምራል፣ እና በአንድ ነጥብ ላይ ሳይታወቅ በቋንቋ ሞዴል ወደተፈጠረ ቀጣይ ጽሑፍ ይቀየራል። በአጠቃላይ ሲነበብ፣ አንድ ወጥ ጽሑፍ ይመስላል — ነገር ግን መሀሉ ላይ በሆነ ቦታ ደራሲው ከሰው ወደ ማሽን ይቀየራል። ተግባራችሁ **ያንን መቀየሪያ ማግኘት** ነው። የሰው ክፍሉ የሚያበቃበትና የማሽኑ ክፍል የሚጀምርበትን የቁምሬ **index**።

እያንዳንዱ sample አንድ string text ነው። በትክክል አንድ boundary አለ። ከእሱ በፊት ያለው ሁሉ በሰው የተጻፈ ነው፤ ከእሱ ጀምሮ ያለው ሁሉ በማሽን የተፈጠረ ነው።

Dataset

Plain-text የቀረቡ የእንግሊዝኛ ምንጣቦች፣ እያንዳንዳቸው አንድ boundary አላቸው።

- **ክፍል A** (hboundary በፊት):- በሰው ከተጻፈ ጽሑፍ የተወሰደ ክፍል።
- **ክፍል B** (hboundary ጀምሮ):- በክፍል A ላይ ተመሥርቶ በቋንቋ ሞዴል የተፈጠረ ቀጣይ ጽሑፍ።
- እያንዳንዱ ወገን ቢያንስ 180 ቃላት አሉት፤ አጠቃላይ ርዝመቱ ~500–800 ቃላት ነው።
- **boundary_char_index** ክፍል A የሚያበቃበት የቁምሬ offset ነው። `text[:boundary_char_index]` የሰው ክፍል ሲሆን `text[boundary_char_index:].lstrip()` የማሽን ክፍል ነው።

የሚሰጣችሁ

ሁለት folders ይሰጣችኋል:-

Folder	Samples	answers.jsonl?	የሚጠቅመው
dataset/train/	1,221	□ ተካትቷል	method-ዎን ለማሰልጠን / fine-tune ለማድረግ
dataset/test_public/	380	□ ተካትቷል (የdev ቅጂ)	pipeline-ዎን ለማስኬድና በአካባቢው ራስዎን ለመመዘን

በምዝና ጊዜ የእርስዎ `dataset/test_public/` folder በተደበቀ የምዝና **set** ይተካል። ተመሳሳይ format አለው፤ ነገር ግን **answers.jsonl** የለውም። notebook-ዎ በዚህ ላይ እንደገና ይሠራል፤ እና የሚያመነጨው `answers.jsonl` ይመዘናል።

- ይፋዊው leaderboard የተደበቀ **test_leaderboard_a** set (380 samples) ይጠቀማል።
- የመጨረሻው ranking የተደበቀ **test_leaderboard_b** set (380 samples) ይጠቀማል።

ሦስቱም የምዝና sets ተመሳሳይ መጠን ያላቸው ሲሆኑ `htrain` ጋር ከተመሳሳይ distribution የተወሰዱ ናቸው፤ ስለዚህ የአካባቢው `dataset/test_public/` score-ዎ የleaderboard score-ዎን በተመጣጣኝ ሁኔታ ይገምታል።

በዲስክ ላይ ያለው format

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only — ABSENT in the hidden grading set
```

- በ`answers.jsonl` ውስጥ ያሉ IDs በ`data.jsonl` ውስጥ ካሉ IDs ጋር ይዛመዳሉ።
- `dataset/train/` (መልሶችን የያዘ) በማሰልጠን ወይም fine-tune በማድረግ ጊዜ ሁሉ ይገኛል።

Output (የsubmission format)

`solution.ipynb` ተብሎ መሰየም ያለበትን አንድ **notebook** ያስገባሉ። ይህ ትክክለኛ የfile ስም አስፈላጊ ነው። ሌላ ማንኛውም ነገር ሳይሠራ ውድቅ ይደረጋል።

notebook-ዎ `dataset/test_public/data.jsonl`ን ማንበብ እና በrepository root ላይ አንድ **answers.jsonl** file መጻፍ አለበት — በእያንዳንዱ መስመር አንድ JSON object፤ እያንዳንዱን sample id እርስዎ ከገመጡት የboundary ቁምሬ index ጋር በማዛመድ:-

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` በ`[0, len(text)]` ውስጥ ያለ integer መሆን አለበት።
- በ`dataset/test_public/data.jsonl` ውስጥ ያለ እያንዳንዱ id በትክክል አንድ ጊዜ መታየት አለበት። በ`answers.jsonl` የጎደለ sample (ወይም integer ያልሆነ / ከrange ውጭ የሆነ value ያለው) ለዚያ sample 0 ነጥብ ያገኛል።

አሰጣጥ

ለእያንዳንዱ sample፣ p እርስዎ የገመቱት index እና t ትክክለኛው boundary ይሁኑ። የእያንዳንዱ sample ነጥብ እንደ የቁምሬ ርቀት በexponential ሁኔታ ይቀንሳል፡-

$$\text{score} = \exp\left(-\frac{|p-t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

ይህ የነጥቡን የሚከተለውን ባህሪ ያስከትላል፡-

- **=1.0** — ትክክለኛው የboundary ቁምሬ፤
- **≈0.78** — በ25 ቁምሬዎች ስህተት፤ - **≈0.61** — በ50 ቁምሬዎች ስህተት፤
- **≈0.37** — በ100 ቁምሬዎች ስህተት፤
- **≈0.01** — በ500 ቁምሬዎች ስህተት።

የመጨረሻው ነጥብ አማካይ ነው፤ ይህም በsplit ውስጥ ባሉ ሁሉም samples ላይ የእያንዳንዱ sample ነጥብ አማካይ ነው (በ0-100 scale ይቀርባል)። metric-ው ትክክለኛውን ብቻ ሳይሆን መቅረብን ይሸልማል።

ገደቦች

- **አካባቢ፡** አንድ GPU (≈16 GB VRAM)፣ በምዘና ጊዜ አንተርኔት የለም — የተፈቀደው model (ከታች) አስቀድሞ ቀርቧል። **የwall-clock ጊዜ ገደብ፡ 10 ደቂቃዎች** ለጠቅላላው ሂደት — ይህ በምዘና ጊዜ የሚያደርጉትን ማንኛውንም training / fine-tuning እና በምዘና set ላይ inference ማድረግን መሸፈን አለበት።
- **የተፈቀደ pretrained model** — ይህ ዝርዝር ሙሉ ነው፤ ሌሎች pretrained weights መጠቀም አይቻልም። ይህ በአካባቢው አስቀድሞ ቀርቧል (በመደበኛው መንገድ load ያድርጉት፣ ለምሳሌ `from_pretrained`፤ በምዘና ጊዜ አንተርኔት የለም)፡-
 - **bge-base-en-v1.5** — 110M-parameter ያለው የጽሑፍ **encoder** (embedding model)። ይህ የsentence/passage embeddings ያመነጫል፤ generative language model አይደለም። ይህንን **እንዳለ (እንደ frozen features) መጠቀም ወይም በtrain split ላይ fine-tune ማድረግ** ይችላሉ (full fine-tuning በ16 GB / 10-minute ገደብ ውስጥ ይሠራል)።
- Classical / statistical tools ገደብ የላቸውም፡- እርስዎ ራስዎ በሚያሰሉት embedding features ላይ ማንኛውንም feature-based model (ለምሳሌ፣ scikit-learn classifiers ወይም regressors) መገንባት ይችላሉ። *Pretrained deep-learning weights* ከላይ ባለው ዝርዝር ብቻ የተገደቡ ናቸው።