

მანქანის აჩრდილი (Ghost of the Machine)

- დროის ლიმიტი: 10 წუთი
- საბაზისო ქულა (**Baseline score**): 28.6
- გარემო: ერთი GPU (≈16 GB VRAM), ინტერნეტის გარეშე
- ამოხსნის ზომა: `solution.ipynb` ≤ 20 MB
- მეხსიერება: 5 GB
- წინასწარ დატრენინგებული მოდელები: მხოლოდ [bge-base-en-v1.5](#) — ტექსტის ენკოდერი (**encoder**) (ემბედინგის მოდელი).

დავალება

ყაზახეთის ეროვნულ არქივში უცნაური ამბები ხდება. ბიბლიოთეკარები ამბობენ, რომ ზოგიერთი წიგნი ადრე სხვანაირად მთავრდებოდა, თუმცა ამის დამტკიცება არავის შეუძლია — თითოეული ეგზემპლარი იდენტურია და თითოეული ისტორია მაინც აზრს ინარჩუნებს. თქვენ, როგორც AI მკვლევარი, მოწვეული ხართ ამ ცვლილებების აღმოსაჩენად.



ტექსტის მონაკვეთი იწყება ადამიანის მიერ დაწერილი ტექსტით და, გარკვეულ მომენტში, უჩუმრად გადადის ენობრივი მოდელის მიერ გენერირებულ გაგრძელებაზე. მთლიანობაში წაკითხვისას ის ერთ შინაარსობრივად გამართულ ტექსტს ჰგავს — თუმცა სადღაც შუაში ავტორი ადამიანიდან მანქანაზე იცვლება. თქვენი დავალებაა იპოვოთ ეს გადასვლა: სიმბოლოს ინდექსი (**character index**), სადაც ადამიანის ნაწილი მთავრდება და იწყება მანქანის ნაწილი.

თითოეული ნიმუში (sample) არის ერთი სტრიქონი `text`. არსებობს ზუსტად ერთი საზღვარი. ყველაფერი მის წინ ადამიანისაა; ყველაფერი მის შემდეგ — მანქანის მიერ გენერირებული.

მონაცემთა სიმრავლე (Dataset)

ჩვეულებრივი ინგლისურენოვანი ტექსტური მონაკვეთები, თითოეული ერთი საზღვრით.

- **ნაწილი A** (საზღვრამდე): ადამიანის მიერ დაწერილი ტექსტის ამონარიდი.
- **ნაწილი B** (საზღვრიდან მოყოლებული): ენობრივი მოდელის მიერ გენერირებული გაგრძელება, ნაწილი A-ზე დაყრდნობით.
- თითოეული მხარე შეიცავს სულ მცირე 180 სიტყვას; საერთო სიგრძეა ~500–800 სიტყვა.
- **boundary_char_index** არის **პირველი ქარაქტერი B ნაწილის**, `text[boundary_char_index:]` არის ზუსტად მანქანის ნაწილი და `text[:boundary_char_index]` არის ადამიანის ნაწილი თავის სფეროსთან ერთად რომელიც ყოფს ამ ორს.

რას იღებთ თქვენ

თქვენ იღებთ ორ საქაღალდეს:

საქაღალდე	ნიმუშები	answers.jsonl?	გამოიყენეთ მისთვის, რომ
dataset/train/	1,221	☐ მოყვება	დაატრენინგოთ / დაახვეწოთ (fine-tune) თქვენი მეთოდი
dataset/test_public/	380	☐ მოყვება (dev-ასლი)	გაუშვათ თქვენი პაიპლაინი (pipeline) და შეაფასოთ საკუთარი შედეგი ლოკალურად

შეფასებისას თქვენი dataset/test_public/ საქაღალდე **ჩანაცვლდება დაფარული საგამოცდო სიმრავლით**. მას აქვს იგივე ფორმატი, მაგრამ **answers.jsonl-ის გარეშე**. თქვენი ნოუტბუქი (notebook) ხელახლა გაეშვება მასზე და მის მიერ გენერირებული answers.jsonl შეფასდება.

- საჯარო ლიდერბორდი იყენებს დაფარულ **test_leaderboard_a** სიმრავლეს (380 ნიმუში).
- საბოლოო რეიტინგი იყენებს დაფარულ **test_leaderboard_b** სიმრავლეს (380 ნიმუში).

სამივე საგამოცდო სიმრავლე არის იგივე ზომის და ალბულობა იმავე განაწილებიდან, საიდანაც train, ასე რომ თქვენი ლოკალური dataset/test_public/ ქულა არის თქვენი ლიდერბორდის ქულის გონივრული შეფასება.

ფორმატი დისკზე

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- id-ები answers.jsonl-ში ემთხვევა id-ებს data.jsonl-ში.
- dataset/train/ (პასუხებით) ხელმისაწვდომია ყოველთვის, როდესაც ტრენინგს ან დახვეწას ახორციელებთ.

გამოსატანი მონაცემები (გაზიარების ფორმატი)

თქვენ აგზავნით **ერთ ნოუტბუქს, რომელსაც აუცილებლად უნდა ერქვას solution.ipynb**. მოითხოვება ზუსტად ეს ფაილის სახელი. ნებისმიერი სხვა ფაილი უარყოფილი იქნება გაშვების გარეშე.

თქვენმა ნოუტბუქმა უნდა წაიკითხოს `dataset/test_public/data.jsonl` და ჩაწეროს ერთი ფაილი `answers.jsonl` რეპოზიტორიის ძირში(Repository Root) — თითო JSON ობიექტი თითო სტრიქონზე, სადაც თითოეული ნიმუშის id ასახულია თქვენ მიერ ფრედქთივად საზღვრის სიმბოლოს ინდექსზე:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` უნდა იყოს მთელი რიცხვი `[0, len(text)]` დიაპაზონში.
- `dataset/test_public/data.jsonl`-ში არსებული თითოეული id უნდა გამოჩნდეს ზუსტად ერთხელ. ნიმუში, რომელიც აკლია `answers.jsonl`-ს (ან აქვს არამთელი / დიაპაზონს გარეთ არსებული მნიშვნელობა), მიიღებს 0 ქულას ამ ნიმუშისთვის.

შეფასება

თითოეული ნიმუშისთვის, დავუშვათ p არის თქვენ მიერ დაფრედქთებული ინდექსი, ხოლო t — ჭეშმარიტი საზღვარი. თითოეული ნიმუშის ქულა ექსპონენციალურად მცირდება სიმბოლოებს შორის მანძილის ზრდასთან ერთად:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

ეს ინვევს ქულის შემდეგ ქცევას:

- **=1.0** — ზუსტი საზღვრის სიმბოლო;
- **≈0.78** — 25 სიმბოლოთი აცდენა; - **≈0.61** — 50 სიმბოლოთი აცდენა;
- **≈0.37** — 100 სიმბოლოთი აცდენა;
- **≈0.01** — 500 სიმბოლოთი აცდენა.

საბოლოო ქულა არის ყველა ნიმუშის ქულების საშუალო (mean) მოცემულ დაყოფაში (ნარმოდგენილი 0–100 შკალაზე). მეტრიკა ასახეურებს *მიახლოებასაც*, და არა მხოლოდ ზუსტ დამთხვევას.

შეზღუდვები

- **გარემო:** ერთი GPU (≈16 GB VRAM), ინტერნეტის გარეშე შეფასებისას — დაშვებული მოდელი (ქვემოთ) უკვე უზრუნველყოფილია. **დროის ბიუჯეტი (Wall-clock budget): 10 წუთი** მთლიანი გაშვებისთვის — მან უნდა დაფაროს ნებისმიერი ტრენინგი / დახვეწა (fine-tuning), რომელსაც შეფასებისას გააკეთებთ, **პლუს** ინფერენსი (inference) საგამოცდო სიმრავლეზე.
- **დაშვებული წინასწარ დატრენინგებული მოდელი** — ეს სია ამომწურავია(exhaustive); სხვა წინასწარ დატრენინგებული წონების გამოყენება აკრძალულია. ის **წინასწარ არის ჩაწერილი გარემოში** (ჩატვირთეთ ჩვეულებრივად, მაგ. `from_pretrained`; შეფასებისას ინტერნეტი არ არის):
 - **bge-base-en-v1.5** — 110M-პარამეტრიანი ტექსტის **ენკოდერი (encoder)** (ემბედიგის მოდელი). ის აგენერირებს წინადადების/მონაკვეთის ემბედიგებს; ის არ არის გენერაციული ენობრივი მოდელი. შეგიძლიათ გამოიყენოთ ის **უცვლელად (გაყინული ფიჩერები / frozen features) ან დააფაინტუნოთ (fine-tune) train დაყოფაზე** (სრული fine-tuning ეტევა 16 GB / 10-წუთიან ბიუჯეტში).
- კლასიკური / სტატისტიკური ინსტრუმენტები არ არის შეზღუდული: შეგიძლიათ ააგოთ ნებისმიერი ნიშნებზე დაფუძნებული მოდელი (მაგ., scikit-learn კლასიფიკატორები ან რეგრესორები) თქვენ მიერ გამოთვლილი ემბედიგების ფიჩერების ბაზაზე. **წინასწარ დატრენინგებული ღრმა სწავლების წონები (pretrained deep-learning weights)** შეზღუდულია მხოლოდ ზემოთ მოცვანილი სიით.