

Το Φάντασμα της Μηχανής

- **Χρονικό όριο:** 10 λεπτά
- **Βαθμολογία baseline:** 28.6
- **Περιβάλλον:** μία GPU (≈16 GB VRAM), χωρίς διαδίκτυο
- **Μέγεθος λύσης:** `solution.ipynb` ≤ 20 MB
- **Αποθηκευτικός χώρος:** 5 GB
- **Προεκπαιδευμένα μοντέλα:** μόνο το [bge-base-en-v1.5](#) — ένας **encoder** κειμένου (μοντέλο embeddings).

Ζητούμενο

Παράξενα πράγματα συμβαίνουν στο Εθνικό Αρχείο του Καζακστάν. Οι βιβλιοθηκονόμοι λένε ότι ορισμένα βιβλία παλαιότερα τελείωναν διαφορετικά, αλλά κανείς δεν μπορεί να το αποδείξει — κάθε αντίτυπο είναι ίδιο και κάθε ιστορία εξακολουθεί να βγάζει νόημα. Καλείστε ως ερευνητής Τεχνητής Νοημοσύνης να εντοπίσετε τις αλλαγές.



Ένα απόσπασμα ξεκινά ως κείμενο γραμμένο από άνθρωπο και, σε κάποιο σημείο, μεταβαίνει ανεπαίσθητα σε μια συνέχεια που δημιουργήθηκε από γλωσσικό μοντέλο. Όταν διαβάζεται ως σύνολο, μοιάζει με ένα ενιαίο συνεκτικό κείμενο — αλλά κάπου στη μέση ο συγγραφέας αλλάζει από άνθρωπο σε μηχανή. Στόχος σας είναι να **βρείτε αυτή τη μετάβαση: τον δείκτη χαρακτήρα όπου τελειώνει το ανθρώπινο μέρος και αρχίζει το μέρος της μηχανής.**

Κάθε δείγμα είναι μία συμβολοσειρά `text`. Υπάρχει ακριβώς ένα όριο. Όλα όσα βρίσκονται πριν από αυτό είναι ανθρώπινα· όλα όσα βρίσκονται από αυτό και μετά είναι δημιουργημένα από μηχανή.

Dataset

Αγγλικά αποσπάσματα απλού κειμένου, με ένα όριο το καθένα.

- **Μέρος Α** (πριν από το όριο): ένα απόσπασμα κειμένου γραμμένο από άνθρωπο.
- **Μέρος Β** (από το όριο και μετά): μια συνέχεια που παράχθηκε από γλωσσικό μοντέλο, με συνθήκη το Μέρος Α.
- Κάθε μέρος περιέχει τουλάχιστον 180 λέξεις· το συνολικό μήκος είναι ~500–800 λέξεις.
- Το `boundary_char_index` είναι η μετατόπιση χαρακτήρα όπου τελειώνει το Μέρος Α: το `text[:boundary_char_index]` είναι το ανθρώπινο μέρος και το `text[boundary_char_index:].lstrip()` είναι το μέρος της μηχανής.

Τι σας παρέχεται

Λαμβάνετε **δύο φακέλους**:

Φάκελος	Δείγματα	<code>answers.jsonl</code> ;	Χρησιμοποιήστε τον για
<code>dataset/train/</code>	1,221	□ περιλαμβάνεται	εκπαίδευση / fine-tuning της μεθόδου σας
<code>dataset/test_public/</code>	380	□ περιλαμβάνεται (αντίγραφο ανάπτυξης)	εκτέλεση του pipeline σας και τοπικό αυτοϋπολογισμό της βαθμολογίας

Κατά τη **βαθμολόγηση**, ο φάκελος `dataset/test_public/` **αντικαθίσταται από ένα κρυφό σύνολο αξιολόγησης**. Έχει την ίδια μορφή, αλλά **χωρίς** `answers.jsonl`. Το notebook σας εκτελείται ξανά σε αυτό και βαθμολογείται το `answers.jsonl` που παράγει.

- Ο δημόσιος πίνακας κατάταξης χρησιμοποιεί ένα κρυφό σύνολο **test_leaderboard_a** (380 δείγματα).
- Η τελική κατάταξη χρησιμοποιεί ένα κρυφό σύνολο **test_leaderboard_b** (380 δείγματα).

Και τα τρία σύνολα αξιολόγησης έχουν το ίδιο μέγεθος και προέρχονται από την ίδια κατανομή με το `train`, επομένως η τοπική σας βαθμολογία `dataset/test_public/` αποτελεί εύλογη εκτίμηση της βαθμολογίας σας στον πίνακα κατάταξης.

Μορφή στον δίσκο

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- Τα αναγνωριστικά (id) στο `answers.jsonl` αντιστοιχούν στα αναγνωριστικά (id) στο `data.jsonl`.
- Το `dataset/train/` (με απαντήσεις) είναι διαθέσιμο κάθε φορά που κάνετε εκπαίδευση ή fine-tuning.

Έξοδος (μορφή υποβολής)

Υποβάλλετε **ένα μόνο notebook**, το οποίο **πρέπει να ονομάζεται** `solution.ipynb`. Απαιτείται ακριβώς αυτό το όνομα αρχείου. Οτιδήποτε άλλο απορρίπτεται χωρίς να εκτελεστεί.

Το notebook σας πρέπει να **διαβάζει το dataset/test_public/data.jsonl** και να γράφει ένα μόνο αρχείο **answers.jsonl** στη ρίζα του repository — ένα αντικείμενο JSON ανά γραμμή, το οποίο αντιστοιχίζει κάθε αναγνωριστικό δείγματος στον προβλεπόμενο δείκτη χαρακτήρα του ορίου:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- Το `boundary_char_index` πρέπει να είναι **ακέραιος στο $[0, \text{len}(\text{text})]$** .
- Κάθε αναγνωριστικό στο `dataset/test_public/data.jsonl` πρέπει να εμφανίζεται ακριβώς μία φορά. Ένα δείγμα που απουσιάζει από το `answers.jsonl` (ή έχει μη ακέραια τιμή / τιμή εκτός εύρους) λαμβάνει βαθμολογία 0 για αυτό το δείγμα.

Βαθμολόγηση

Για κάθε δείγμα, έστω p ο προβλεπόμενος δείκτης σας και t το πραγματικό όριο. Η βαθμολογία ανά δείγμα μειώνεται εκθετικά με την απόσταση σε χαρακτήρες:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Αυτό οδηγεί στην ακόλουθη συμπεριφορά της βαθμολογίας:

- **=1.0** — ακριβώς στον χαρακτήρα του ορίου.
- **≈0.78** — απόκλιση 25 χαρακτήρων · **≈0.61** — απόκλιση 50 χαρακτήρων.
- **≈0.37** — απόκλιση 100 χαρακτήρων.
- **≈0.01** — απόκλιση 500 χαρακτήρων.

Η **τελική βαθμολογία είναι ο μέσος όρος** των βαθμολογιών ανά δείγμα για όλα τα δείγματα του διαμερίσματος (αναφέρεται σε κλίμακα 0–100). Η μετρική επιβραβεύει την εγγύτητα και όχι μόνο την ακρίβεια.

Περιορισμοί

- **Περιβάλλον:** μία GPU (≈16 GB VRAM), χωρίς διαδίκτυο κατά τη βαθμολόγηση — το επιτρεπόμενο μοντέλο (παρακάτω) παρέχεται ήδη. **Χρονικό όριο εκτέλεσης: 10 λεπτά** για ολόκληρη την εκτέλεση — αυτό πρέπει να καλύπτει οποιαδήποτε εκπαίδευση / fine-tuning πραγματοποιείτε κατά τη βαθμολόγηση **συν** την εξαγωγή προβλέψεων στο σύνολο αξιολόγησης.
- **Επιτρεπόμενο προεκπαιδευμένο μοντέλο** — η παρακάτω λίστα είναι εξαντλητική· δεν επιτρέπεται η χρήση άλλων προεκπαιδευμένων βαρών. **Παρέχεται εκ των προτέρων στο περιβάλλον** (φορτώστε το κανονικά, π.χ. `from_pretrained`· δεν υπάρχει διαδίκτυο κατά τη βαθμολόγηση):
 - **bge-base-en-v1.5** — ένας **encoder** κειμένου 110M παραμέτρων (μοντέλο embeddings). Παράγει embeddings προτάσεων/αποσπασμάτων· δεν είναι παραγωγικό γλωσσικό μοντέλο. Μπορείτε να το χρησιμοποιήσετε **ως έχει (με παγωμένα χαρακτηριστικά)** ή να **κάνετε fine-tuning στο διαμέρισμα train** (το πλήρες fine-tuning χωρά στον προϋπολογισμό των 16 GB / 10 λεπτών).
- Τα κλασικά / στατιστικά εργαλεία δεν υπόκεινται σε περιορισμούς: μπορείτε να δημιουργήσετε οποιοδήποτε μοντέλο βασισμένο σε χαρακτηριστικά (π.χ. ταξινομητές ή παλινδρομητές του scikit-learn) πάνω από χαρακτηριστικά embeddings που υπολογίζετε εσείς. Τα προεκπαιδευμένα βάρη βαθιάς μάθησης περιορίζονται μόνο στη λίστα παραπάνω.