

A gép szelleme

- **Időkorlát:** 10 perc
- **Alappontszám (baseline):** 28.6
- **Környezet:** egy GPU (≈16 GB VRAM), internetkapcsolat nélkül
- **A megoldás mérete:** `solution.ipynb` ≤ 20 MB
- **Tárhely:** 5 GB
- **Előre betanított modellek:** kizárólag a [bge-base-en-v1.5](#) — egy szövegenkóder (embedding/beágyazó modell).

Feladat

Különös dolgok történnek a Kazah Nemzeti Levéltárban. A könyvtárosok szerint egyes könyvek korábban máshogy végződtek, de ezt senki sem tudja bizonyítani — minden példány ugyanolyan, és továbbra is minden történet értelmes. Önt MI-kutatóként felkéri a változtatások helyének meghatározására.



Egy szövegrészlet ember által írt szöveggént kezdődik, majd egy ponton észrevétlenül egy nyelvi modell által generált folytatásra vált. Egészként olvasva egyetlen összefüggő műnek tűnik — de valahol középen a szerző emberről gépre változik. Az Ön feladata **megtalálni ezt a váltást: azt a karakterindexet, ahol az emberi rész véget ér, és a gépi rész elkezdődik**.

Minden minta egyetlen `text` sztring. Pontosan egy határ van. Minden, ami előtte található, emberi; minden, ami attól kezdve található, gép által generált.

Adatok (Dataset)

Egyszerű szöveges (plain text) angol nyelvű részletek, mindegyikben egy határral.

- **A rész** (a határ előtti): részlet egy ember által írt szövegből.
- **B rész** (a határtól kezdve): mesterséges folytatás, amit egy nyelvi modell generált. A nyelvi modell az A részre volt kondicionálva.
- Mindkét oldal legalább 180 szóból áll; a teljes hossz ~500–800 szó.
- A `boundary_char_index` az a karakterpozíció, ahol a B rész kezdődik: a `text[boundary_char_index:]` a gép alkotta rész és a `text[:boundary_char_index]` az ember alkotta rész, a két részt elválasztó egyetlen szóközzel együtt.

Amit megkap

Két mappát kap:

Mappa	Minták száma	answers.jsonl?	Felhasználás
dataset/train/	1,221	□ mellékelve	a módszer betanítása / finomhangolása
dataset/test_public/	380	□ mellékelve (a fejlesztés alatt)	a pipeline futtatása és helyi kiértékelés (self-score)

Értékeléskor az Ön `dataset/test_public/` mappáját **egy rejtett teszt (kiértékelési) halmaz váltja fel**. Ennek formátuma megegyezik a nyilvánossal, de **nem tartalmaz answers.jsonl** fájlt. Az Ön notebookját ezen újrafuttatják, és az általa előállított `answers.jsonl` kerül pontozásra.

- A nyilvános ranglista egy rejtett **test_leaderboard_a** halmazt használ (380 minta).
- A végső rangsorolás egy rejtett **test_leaderboard_b** halmazt használ (380 minta).

Mindhárom értékelési halmaz azonos méretű, és ugyanabból az eloszlásból származik, mint a `train`, ezért az Ön helyi `dataset/test_public/` pontszáma észszerű becslést ad a ranglistán elérhető pontszámára.

Lemezen tárolt formátum

```
dataset/train/data.jsonl      # egy JSON objektum soronként: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # csak a fejlesztés alatt – NEM elérhető a rejtett teszt (kiértékelési) halmaz
```

- A `answers.jsonl` azonosítói megfelelnek a `data.jsonl` azonosítóinak.
- A `dataset/train/` (a válaszokkal együtt) mindig elérhető, amikor Ön betanítást vagy finomhangolást végez.

Kimenet (a beadás formátuma)

Önnek **egyetlen notebookot kell beadnia, amelynek neve kötelezően solution.ipynb**. Pontosan ez a fájlnev szükséges. Minden más fájl futtatás nélkül elutasítanak.

A notebooknak **be kell olvasnia a dataset/test_public/data.jsonl fájlt**, és egyetlen `answers.jsonl` fájlt kell írnia a repository gyökérkönyvtárába — soronként egy JSON-objektummal, amely minden minta azonosítójához hozzárendeli az Ön által előre jelzett határ karakterindexét:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- A `boundary_char_index` értékének **a `[0, len(text)]` tartományba eső egész számnak kell lennie**.
- A `dataset/test_public/data.jsonl` minden azonosítójának pontosan egyszer kell szerepelnie. Minden, a `answers.jsonl` fájlból hiányzó minta (vagy nem egész / tartományon kívüli érték) 0 pontot kap az adott mintára.

Pontozás

Minden mintánál legyen p az Ön által előre jelzett index, t pedig a valódi határ. A mintánkénti pontszám exponenciálisan csökken a karaktértávolsággal:

$$\text{pontszám} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ ahol } \tau = 100.$$

Ez a pontszám következő viselkedéséhez vezet:

- **≈1.0** — pontos a határkarakter érték;
- **≈0.78** — 25 karakter eltérés; **≈0.61** — 50 karakter eltérés;
- **≈0.37** — 100 karakter eltérés;
- **≈0.01** — 500 karakter eltérés.

A **végső pontszám a mintánkénti pontszámok átlaga** az adott halmaz összes mintájára (0–100 közé átskálázva). Ez a metrika a *közel*i eredményt is jutalmazza, nem csupán a pontosat.

Korlátozások

- **Környezet:** egy GPU (≈16 GB VRAM), az értékeléskor internetkapcsolat nélkül — az engedélyezett modell (lásd alább) már rendelkezésre áll.
- **Futtatási időkeret: 10 perc** a teljes futtatásra — ennek magában kell foglalnia az értékeléskor végzett minden betanítást / finomhangolást és az értékelési halmazon végzett inferenciát.

- **Engedélyezett előre betanított modell** — a lista teljes körű; semmilyen más előre betanított súly nem használható. A modell **előre rendelkezésre áll a környezetben** (a szokásos módon töltsse be, például `from_pretrained`; az értékeléskor nincs internetkapcsolat):
 - **bge-base-en-v1.5** — egy 110M-paraméteres szövegenkóder (embedding/beágyazó modell). Mondat- és szövegrészlet-embeddingeket állít elő; nem generatív nyelvi modell. Ön használhatja **változtatlanul (befagyasztott jellemzőkkel), vagy finomhangolhatja a train halmazon** (a teljes finomhangolás belefér a 16 GB / 10-perces keretbe).
- A klasszikus / statisztikai eszközök használata nincs korlátozva: bármilyen jellemzőalapú (feature-based) modellt építhet (például scikit-learn-osztályozókat vagy -regresszorokat) a saját maga által kiszámított embeddingjellemezőkre. Az *előre betanított mélytanulási súlyok* használata viszont kizárólag a fenti listára van korlátozva.