

機械の亡霊

- 制限時間: 10 minutes
- ベースラインスコア: 28.6
- 環境: GPU 1基 (≈16 GB VRAM) 、インターネット接続なし
- 解答サイズ: `solution.ipynb` ≤ 20 MB
- ストレージ: 5 GB
- 事前学習済みモデル: [bge-base-en-v1.5](#) のみ — テキストエンコーダ (embedding model) 。

課題

Kazakhstan国立公文書館で奇妙なことが起きています。司書たちは、一部の本は以前と異なる結末だったと言いますが、誰もそれを証明できません。どの写しも同じであり、どの物語にも依然として筋が通っているからです。あなたはAI研究者として、変更箇所を特定するよう招かれました。



ある文章は人間が書いたテキストとして始まり、途中のある時点で、ひそかに言語モデルが生成した続きへと切り替わります。全体として読むと、1つの一貫した文章に見えますが、途中のどこかで書き手が人間から機械へと変わります。あなたの課題は、その切り替わり、すなわち人間による部分が終わり、機械による部分が始まる文字インデックスを見つけることです。

各サンプルは1つの文字列 `text` です。境界はちょうど1つあります。境界より前はすべて人間によるものであり、境界以降はすべて機械によって生成されたものです。

データセット

境界をそれぞれ1つ含む、プレーンテキストの英語文章です。

- **Part A**（境界より前）：人間が書いたテキストの抜粋。
- **Part B**（境界以降）：Part Aを条件として言語モデルが生成した続き。
- 各部分は少なくとも180 wordsで、全体の長さは~500–800 wordsです。
- **boundary_char_index** はPart Aが終わる文字オフセットです。 `text[:boundary_char_index]` は人間による部分であり、 `text[boundary_char_index:].lstrip()` は機械による部分です。

提供されるもの

2つのフォルダが提供されます。

フォルダ	サンプル数	answers.jsonl?	用途
dataset/train/	1,221	☒ 含まれる	手法の学習／fine-tuning
dataset/test_public/	380	☒ 含まれる（dev用コピー）	パイプラインの実行とローカルでの自己採点

採点時には、dataset/test_public/ フォルダが**非公開の評価セット**に置き換えられます。形式は同じですが、**answers.jsonl は含まれません**。その評価セットに対してnotebookが再実行され、notebookが生成したanswers.jsonl が採点されます。

- 公開leaderboardでは、非公開の **test_leaderboard_a** セット（380 samples）を使用します。
- 最終順位では、非公開の **test_leaderboard_b** セット（380 samples）を使用します。

3つの評価セットはすべて同じサイズであり、trainと同じ分布から抽出されているため、ローカルでのdataset/test_public/ スコアはleaderboardスコアの妥当な推定値となります。

ディスク上の形式

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- answers.jsonl 内のIDは、data.jsonl 内のIDと一致します。
- 学習またはfine-tuningを行う際には、dataset/train/（正解付き）を利用できます。

出力（提出形式）

solution.ipynb という名前の、**単一のnotebook**を提出します。この正確なファイル名が必須です。それ以外のもものは実行されずに却下されます。

notebook は **dataset/test_public/data.jsonl** を読み込み、リポジトリのルートに単一のファイル **answers.jsonl** を書き出さなければなりません。各行には、各サンプルIDを予測した境界の文字インデックスに対応付けるJSON objectを1つずつ出力します。

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` は、`[0, len(text)]` 内の整数でなければなりません。
- `dataset/test_public/data.jsonl` 内のすべてのIDは、ちょうど1回ずつ現れるべきです。`answers.jsonl` に含まれていないサンプル（または値が整数でない、もしくは範囲外であるサンプル）は、そのサンプルについて0点となります。

採点

各サンプルについて、 p を予測したインデックス、 t を真の境界とします。サンプルごとのスコアは、文字単位の距離に応じて指数関数的に減衰します。

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

これにより、スコアは次のように変化します。

- **=1.0** — 境界の文字と完全に一致。
- **≈0.78** — 25 charactersのずれ。 - **≈0.61** — 50 charactersのずれ。
- **≈0.37** — 100 charactersのずれ。
- **≈0.01** — 500 charactersのずれ。

最終スコアは、**split(データセット)内の全サンプルに対するサンプルごとのスコアの平均**です（0–100 scaleで報告されます）。このmetricでは、完全一致だけでなく、境界に近い予測も評価されます。

制約

- **環境:** GPU 1基（≈16 GB VRAM）、採点時にはインターネット接続なし — 以下で許可されているモデルはすでに提供されています。実行全体の**実時間制限は10 minutes**です。これには、採点時に行うすべての学習／fine-tuningと、評価セットに対する推論の**両方**が含まれなければなりません。
- **使用可能な事前学習済みモデル** — 以下がすべてであり、他の事前学習済みweightsは使用できません。このモデルは**環境内に事前に用意されています**（通常どおり、たとえば `from_pretrained` として読み込んでください。採点時にはインターネット接続がありません）。
 - **bge-base-en-v1.5** — 110M-parameterのテキストエンコーダ（embedding model）。sentence/passage embeddingsを生成するものであり、生成言語モデルではありません。**そのまま（frozen featuresとして）使用することも、train splitでfine-tuningすることもできます**（full fine-tuningは16 GB / 10-minuteの制限内で実行可能です）。
- 古典的／統計的ツールの使用には制限がありません。自分で計算したembedding featuresの上に、任意のfeature-based model（たとえばscikit-learnのclassifierまたはregressor）を構築できます。**事前学習済みdeep-learning weights**に関する制限は、上記のリストにあるものだけです。