

Mašīnas spoks

- **Laika ierobežojums:** 10 minūtes
- **Bāzlīnijas (baseline) rezultāts:** 28.6
- **Vide:** viens GPU (≈ 16 GB VRAM), nav interneta
- **Risinājuma izmērs:** `solution.ipynb` ≤ 20 MB
- **Krātuve:** 5 GB
- **Iepriekš apmācītie modeļi:** tikai [bge-base-en-v1.5](#) — teksta **kodētājs** (embedding modelis).

Uzdevums

Kazahstānas Nacionālajā arhīvā notiek dīvainas lietas. Bibliotekāri stāsta, ka dažas grāmatas agrāk beidzās citādi, taču neviens to nevar pierādīt — visi eksemplāri ir vienādi, un katrs stāsts joprojām ir loģisks. Jūs esat aicināts kā AI pētnieks atrast izmaiņas.



Fragments sākas kā cilvēka rakstīts teksts un kādā brīdī klusi pārslēdzas uz valodas modeļa ģenerētu turpinājumu. Lasot to kā vienotu veselumu, tas izskatās kā viens saskanīgs teksts — taču kaut kur vidū autors mainās no cilvēka uz mašīnu. Jūsu uzdevums ir **atrst šo pārslēgšanos: rakstzīmes indeksu, kur beidzas cilvēka daļa un sākas mašīnas daļa**.

Katrs paraugs ir viena virkne `text`. Ir tieši viena robeža. Viss, kas atrodas pirms tās, ir cilvēka veidots; viss, sākot no tās, ir mašīnas ģenerēts.

Datu kopa

Vienkārša teksta fragmenti angļu valodā, katram viena robeža.

- **A daļa** (pirms robežas): cilvēka rakstīta teksta izvilkums.
- **B daļa** (no robežas tālāk): valodas modeļa radīts turpinājums, kas nosacīts ar A daļu.
- Katra puse ir vismaz 180 vārdu gara; kopējais garums ir ~500–800 vārdu.
- **boundary_char_index** ir rakstzīmju nobīde, kurā beidzas A daļa: `text[:boundary_char_index]` ir cilvēka daļa un `text[boundary_char_index:].rstrip()` ir mašīnas daļa.

Ko jūs saņemat

Jūs saņemat **divas mapes**:

Mape	Paraugi	<code>answers.jsonl</code> ?	Izmantojiet to, lai
<code>dataset/train/</code>	1,221	☐ iekļauts	apmācītu / veiktu fine-tuning savai metodei
<code>dataset/test_public/</code>	380	☐ iekļauts (izstrādes kopija)	palaistu savu pipeline un lokāli pašnovērtētu rezultātu

Vērtēšanas laikā jūsu `dataset/test_public/` mape tiek **aizstāta ar slēptu vērtēšanas kopu**. Tai ir tāds pats formāts, bet **bez `answers.jsonl`**. Jūsu notebook tiek atkārtoti palaists uz tās, un tā radītais `answers.jsonl` tiek novērtēts.

- Publiskais leaderboard izmanto slēptu **test_leaderboard_a** kopu (380 paraugi).
- Gala ranžējums izmanto slēptu **test_leaderboard_b** kopu (380 paraugi).

Visas trīs vērtēšanas kopas ir vienāda izmēra un iegūtas no tā paša sadalījuma kā `train`, tāpēc jūsu lokālais `dataset/test_public/` rezultāts ir saprātīgs novērtējums jūsu leaderboard rezultātam.

Formāts diskā

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- Id vērtības failā `answers.jsonl` atbilst id vērtībām failā `data.jsonl`.
- `dataset/train/` (ar atbildēm) ir pieejams vienmēr, kad apmācāt vai veicat fine-tuning.

Izvide (iesniegšanas formāts)

Jūs iesniedzat **vienu notebook**, kuram jābūt nosauktam **`solution.ipynb`**. Šis precīzais faila nosaukums ir obligāts. Jebkas cits tiek atteikts, to nemaz nepalaižot.

Jūsu notebook ir jānolasa `dataset/test_public/data.jsonl` un jāizveido viens fails `answers.jsonl` repozitorija saknē — viens JSON objekts katrā rindā, kas katram parauga id piekārto jūsu prognozēto robežas rakstzīmes indeksu:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` jābūt veselam skaitlim diapazonā `[0, len(text)]`.

- Katram id no `dataset/test_public/data.jsonl` jāparādās tieši vienu reizi. Paraugs, kas nav atrodams failā `answers.jsonl` (vai kuram ir vērtība, kas nav vesels skaitlis / ir ārpus diapazona), saņem 0 punktus par šo paraugu.

Vērtēšana

Katram paraugam lai p ir jūsu prognozētais indekss un t — patiesā robeža. Katra parauga rezultāts eksponenciāli samazinās atkarībā no rakstzīmju attāluma:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Tas rada šādu rezultāta uzvedību:

- **≈1.0** — precīza robežas rakstzīme;
- **≈0.78** — 25 rakstzīmju nobīde; - **≈0.61** — 50 rakstzīmju nobīde;
- **≈0.37** — 100 rakstzīmju nobīde;
- **≈0.01** — 500 rakstzīmju nobīde.

Gala rezultāts ir vidējais no katra parauga rezultātiem visos šī sadalījuma paraugos (uzrādīts 0–100 skalā). Metrika atalgo par *tuvu* atbildi, ne tikai par precīzu.

Ierobežojumi

- **Vide:** viens GPU (≈16 GB VRAM), vērtēšanas laikā nav interneta — atļautais modelis (zemāk) jau ir nodrošināts. **Reālā laika (wall-clock) budžets: 10 minūtes** visam izpildījumam — tam jāietver jebkāda apmācība / fine-tuning, ko veicat vērtēšanas laikā, **plus** inference uz vērtēšanas kopas.
- **Atļautais iepriekš apmācītais modelis** — šis saraksts ir izsmeļošs; nekādi citi iepriekš apmācīti svāri nedrīkst tikt izmantoti. Tas ir **iepriekš nodrošināts vidē** (ielādējiet to parastā veidā, piemēram, `from_pretrained`; vērtēšanas laikā nav interneta):
 - **bge-base-en-v1.5** — teksta **kodētājs** (embedding modelis) ar 110M parametriem. Tas veido teikumu/fragmentu embeddings; tas nav ģeneratīvs valodas modelis. Jūs varat to izmantot **tādu, kāds tas ir (iesaldētas pazīmes), vai veikt tam fine-tuning uz train sadalījuma** (pilns fine-tuning iekļaujas 16 GB / 10 minūšu budžetā).
- Klasiskie / statistiskie rīki nav ierobežoti: jūs varat veidot jebkādu uz pazīmēm balstītu modeli (piemēram, scikit-learn klasifikatorus vai regresorus) virs embedding pazīmēm, kuras aprēķināt paši. *Iepriekš apmācīti dziļās mašīnmācīšanās svāri* ir ierobežoti tikai ar iepriekš minēto sarakstu.