

Fantoma mașinii

- **Limită de timp:** 10 minute
- **Scor de referință:** 28.6
- **Mediu:** un GPU (≈ 16 GB VRAM), fără internet
- **Dimensiunea soluției:** `solution.ipynb` ≤ 20 MB
- **Spațiu de stocare:** 5 GB
- **Modele preantrenate:** doar [bge-base-en-v1.5](#) — un **encoder** de text (model de embedding).

Sarcină

La Arhiva Națională a Kazahstanului se întâmplă lucruri ciudate. Bibliotecarii spun că unele cărți aveau înainte finaluri diferite, dar nimeni nu poate dovedi acest lucru — fiecare exemplar este identic și fiecare poveste continuă să aibă sens. Sunteți invitați, în calitate de cercetători în IA, să localizați modificările.



Un pasaj începe ca text scris de un om și, la un moment dat, trece neobservat la o continuare generată de un model lingvistic. Citit în întregime, pare un text coerent — dar undeva, la mijloc, autorul se schimbă dintr-o persoană într-o mașină. Sarcina dumneavoastră este să **găsiți acea trecere: indicele caracterului la care partea scrisă de om se încheie și începe partea generată de mașină**.

Fiecare eșantion este un singur șir de caractere `text`. Există exact o singură graniță. Tot ce se află înaintea ei este scris de om; tot ce se află începând de la ea este generat de mașină.

Dataset

Pasaje în limba engleză, în format text simplu, fiecare având o singură graniță.

- **Partea A** (înainte de graniță): un fragment de text scris de un om.
- **Partea B** (începând de la graniță): o continuare produsă de un model lingvistic, condiționată de Partea A.
- Fiecare parte are cel puțin 180 de cuvinte; lungimea totală este de ~500–800 de cuvinte.
- **boundary_char_index** este decalajul în caractere la care se încheie Partea A: `text[:boundary_char_index]` este partea scrisă de om, iar `text[boundary_char_index:].lstrip()` este partea generată de mașină.

Ce primiți

Primiți **două** directoare:

Director	Eșantioane	<code>answers.jsonl</code> ?	Folosiți-l pentru
<code>dataset/train/</code>	1,221	☐ inclus	antrenarea / ajustarea fină a metodei dumneavoastră
<code>dataset/test_public/</code>	380	☐ inclus (copie dev)	rularea pipeline-ului dumneavoastră și calcularea locală a propriului scor

La **momentul evaluării**, directorul dumneavoastră `dataset/test_public/` este **înlocuit cu un set de evaluare ascuns**. Acesta are același format, dar **fără** `answers.jsonl`. Notebook-ul dumneavoastră este rulat din nou pe acesta, iar `answers.jsonl` pe care îl produce este evaluat.

- Clasamentul public folosește un set ascuns **test_leaderboard_a** (380 de eşantioane).
- Clasamentul final folosește un set ascuns **test_leaderboard_b** (380 de eşantioane).

Toate cele trei seturi de evaluare au aceeași dimensiune și sunt extrase din aceeași distribuție ca `train`, astfel încât scorul dumneavoastră local `dataset/test_public/` reprezintă o estimare rezonabilă a scorului dumneavoastră din clasament.

Formatul de pe disc

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- ID-urile din `answers.jsonl` corespund ID-urilor din `data.jsonl`.
- `dataset/train/` (cu răspunsuri) este disponibil ori de câte ori antrenați sau efectuați ajustarea fină.

Ieșire (formatul trimiterii)

Trimiteți **un singur notebook, care trebuie să fie denumit `solution.ipynb`**. Este obligatoriu acest nume exact de fișier. Orice altceva este respins fără a fi rulat.

Notebook-ul dumneavoastră trebuie să **citească** `dataset/test_public/data.jsonl` și să scrie un singur fișier **`answers.jsonl`** în rădăcina repository-ului — câte un obiect JSON pe linie, care asociază fiecare ID de eşantion cu indicele în caractere prezis pentru graniță:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` trebuie să fie un **număr întreg din $[0, \text{len}(\text{text})]$** .
- Fiecare ID din `dataset/test_public/data.jsonl` trebuie să apară exact o dată. Un eșantion care lipsește din `answers.jsonl` (sau are o valoare care nu este un număr întreg / este în afara intervalului) primește scorul 0 pentru acel eșantion.

Evaluare

Pentru fiecare eșantion, fie p indicele prezis de dumneavoastră și t granița reală. Scorul per eșantion scade exponențial în funcție de distanța în caractere:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Aceasta conduce la următorul comportament al scorului:

- **≈ 1.0** — caracterul exact al graniței;
- **≈ 0.78** — abatere de 25 de caractere; - **≈ 0.61** — abatere de 50 de caractere;
- **≈ 0.37** — abatere de 100 de caractere;
- **≈ 0.01** — abatere de 500 de caractere.

Scorul final este media scorurilor per eșantion pentru toate eșantioanele din subset (raportată pe o scară de la 0–100). Metrica recompensează apropierea, nu doar exactitatea.

Constrângeri

- **Mediu:** un GPU (≈ 16 GB VRAM), fără internet la momentul evaluării — modelul permis (de mai jos) este deja furnizat. **Buget de timp efectiv: 10 minute** pentru întreaga rulare — acesta trebuie să includă orice antrenare / ajustare fină pe care o efectuați la momentul evaluării, **precum și** inferența pe setul de evaluare.
- **Model preantrenat permis** — această listă este exhaustivă; nu pot fi utilizate alte ponderi preantrenate. Acesta este **furnizat în prealabil în mediu** (încărcați-l în mod normal, de exemplu `from_pretrained`; nu există internet la momentul evaluării):
 - **`lgb-base-en-v1.5`** — un **encoder** de text cu 110M de parametri (model de embedding). Acesta produce embedding-uri pentru propoziții/pasaje; nu este un model lingvistic generativ. Îl puteți utiliza **ca atare (cu caracteristici înghețate)** sau îl puteți ajusta fin pe subsetul `train` (ajustarea fină completă se încadrează în bugetul de 16 GB / 10 minute).
- Instrumentele clasice / statistice nu sunt restricționate: puteți construi orice model bazat pe caracteristici (de exemplu, clasificatori sau regresori `scikit-learn`) peste caracteristicile de embedding pe care le calculați dumneavoastră. Restricția privind *ponderile preantrenate de deep learning* se aplică doar listei de mai sus.