

Машины сүнс

- **Хугацааны хязгаар:** 10 минут
- **Суурь загварын оноо:** 28.6
- **Орчин:** нэг GPU (≈ 16 GB VRAM), интернетгүй
- **Шийдлийн хэмжээ:** `solution.ipynb` ≤ 20 MB
- **Хадгалах багтаамж:** 5 GB
- **Урьдчилан сургасан загварууд:** зөвхөн [bge-base-en-v1.5](#) — текстийн **энкодер** (embedding загвар).

Даалгавар

Казахстаны Үндэсний архивт хачирхалтай зүйлс тохиолдож байна. Номын санчид зарим ном өмнө нь өөрөөр төгсдөг байсан гэж хэлж байгаа ч хэн ч үүнийг нотолж чадахгүй — бүх хувь нь адилхан бөгөөд бүх түүх утга учиртай хэвээр байна. Тэхрхүү өөрчлөлтүүдийг олуулахаар, таныг хиймэл оюуны судлаачаар урьжээ.



Нэг эх бичвэр хүний бичсэн текстээр эхэлж, тодорхой нэг цэгээс эхлэн хэлний загвараар үүсгэсэн үргэлжлэл рүү үл мэдэг шилжинэ. Бүхэлд нь уншихад нэгэн уялдаатай бүтээл мэт харагдана — гэхдээ дунд хэсгийн хаа нэгтээ зохиогч нь хүнээс машин болж өөрчлөгдөнө. Таны даалгавар бол **тэр шилжилтийг буюу хүний бичсэн хэсэг төгсөж, машины бичсэн хэсэг эхлэх тэмдэгтийн индексийг олох** юм.

Өгөгдлийн сорьц (sample) бүр `text` гэсэн нэг тэмдэгт мөр байна. Яг нэг л зааг бий. Түүний өмнөх бүх зүйл хүнийх; түүнээс хойших бүх зүйл машинаар үүсгэгдсэн байна.

Өгөгдлийн багц

Энгийн текст хэлбэрийн англи эхүүд бөгөөд тус бүр нэг заагтай.

- **А хэсэг** (заагийн өмнө): хүний бичсэн текстийн хэсэг.
- **В хэсэг** (заагаас эхлэн): А хэсэгт нөхцөлдүүлэн хэлний загвараар үүсгэсэн үргэлжлэл.
- Тал бүр дор хаяж 180 үгтэй; нийт урт нь ~500–800 үг.
- **boundary_char_index** нь **В хэсгийн хамгийн эхний тэмдэгтийн** индекс: `text[boundary_char_index:]` нь машины бичсэн хэсэг, `text[:boundary_char_index]` нь хүний бичсэн хэсэг бөгөөд төгсгөлдөө хоёр хэсгийг тусгаарласан нэг хоосон зайтай.

Танд өгөх зүйлс

Та **хоёр хавтас** хүлээн авна:

Хавтас	Сорьцын хэмжээ	answers.jsonl?	Үүнийг ашиглах зорилго
dataset/train/	1,221	□ багтсан	аргаа сургах / хөглөн-сургах (fine-tuning)
dataset/test_public/	380	□ багтсан (хөгжүүлэлтийн хуулбар)	дамжлагаа ажиллуулж, оноогоо локал орчинд тооцох

Үнэлэх үед таны `dataset/test_public/` хавтсыг **далд үнэлгээний багцаар солино**. Энэ нь ижил форматтай боловч **answers.jsonl-гүй** байна. Таны notebook-ийг түүн дээр дахин ажиллуулж, үүсгэсэн `answers.jsonl`-д нь оноо өгнө.

- Нийтийн онооны самбарт далд **test_leaderboard_a** багцыг (380 сорьц) ашиглана.
- Эцсийн эрэмбэд далд **test_leaderboard_b** багцыг (380 сорьц) ашиглана.

Үнэлгээний гурван багц бүгд ижил хэмжээтэй бөгөөд `train`-тэй ижил тархалтаас авсан тул таны локал орчинд `dataset/test_public/` өгөгдлөөс тооцсон оноо нь онооны самбар дээрх оноог боломжийн түвшинд илэрхийлнэ.

Диск дээрх формат

```
dataset/train/data.jsonl      # мөр бүр нэг JSON объект: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – үнэлгээний нууц багцад БАЙХГҮЙ
```

- `answers.jsonl` дахь ID утгууд `data.jsonl` дахь ID-тай таарна.
- `dataset/train/` (хариутай) нь та үүнийг сургах, хөглөн-сургахад ашиглах боломжтой.

Гаралт (илгээлтийн формат)

Та **solution.ipynb** нэртэй байх ёстой ганц **notebook** илгээнэ. Яг энэ файлын нэрийг заавал хэрэглэнэ. Өөр нэртэй аливаа зүйлийг ажиллуулахгүйгээр хүлээн авахаас татгалзана.

Таны notebook `dataset/test_public/data.jsonl`-ийг уншиж, репозиторийн үндсэн директорт `answers.jsonl` гэсэн нэг файл бичих ёстой — мөр бүрд нэг JSON объект байх бөгөөд сорьц бүрийн ID-г таны таамагласан заагийн тэмдэгтийн индекстэй харгалзуулна:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` нь `[0, len(text)]` доторх бүхэл тоо байх ёстой.
- `dataset/test_public/data.jsonl` дахь ID бүр яг нэг удаа гарах ёстой. `answers.jsonl`-оос дутуу сорьц (эсвэл бүхэл тоо биш / мужаас гадуурх утгатай сорьц) тухайн сорьцод 0 оноо авна.

Үнэлгээ

Сорьц бүрийн хувьд p нь таны таамагласан индекс, t нь жинхэнэ зааг байг. Сорьц тус бүрийн оноо тэмдэгтийн зайнаас хамааран экспоненциалаар буурна:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Ингэснээр оноо дараах шинжийг үзүүлнэ:

- **=1.0** — заагийн тэмдэгтийг яг олсон;
- **≈0.78** — 25 тэмдэгтийн зөрүүтэй;
- **≈0.61** — 50 тэмдэгтийн зөрүүтэй;
- **≈0.37** — 100 тэмдэгтийн зөрүүтэй;
- **≈0.01** — 500 тэмдэгтийн зөрүүтэй.

Эцсийн оноо нь тухайн хуваалтын бүх сорьцын сорьц тус бүрийн онооны дундаж байна (0–100 хуваариар тайлагнана). Энэ хэмжүүр нь зөвхөн яг олохоос гадна *ойрхон* олоход урамшуулал өгнө.

Хязгаарлалтууд

- **Орчин:** нэг GPU (≈16 GB VRAM), үнэлэх үед интернетгүй — зөвшөөрөгдсөн загварыг (доор) урьдчилан өгсөн байна. Бүх ажилд зориулсан **бодит хугацааны төсөв: 10 минут** — үүнд үнэлэх үед хийх аливаа сургалт / хөглөн-сургалт **болон** үнэлгээний багц дээрх таамаглал гаргалт бүгд багтах ёстой.
- **Зөвшөөрөгдсөн урьдчилан сургасан загвар** — энэ жагсаалт бүрэн бөгөөд өөр ямар ч урьдчилан сургасан жин ашиглаж болохгүй. Загварыг **орчинд урьдчилан өгсөн** (ердийн байдлаар ачаална, жишээлбэл `from_pretrained`; үнэлэх үед интернет байхгүй):
 - **bge-base-en-v1.5** — 110M параметртэй текстийн **энкодер** (embedding загвар). Энэ нь өгүүлбэр/эхийн embedding үүсгэдэг; генератив хэлний загвар биш. Та үүнийг **байгаагаар нь (царцаасан онцлогууд) ашиглах эсвэл train хуваалт дээр хөглөн-сургалт хийх** боломжтой (бүрэн хөглөн-сургалт нь 16 GB / 10 минутын төсөвт багтана).
- Сонгодог / статистикийн хэрэгслүүдэд хязгаарлалтгүй: та өөрөө тооцоолсон embedding онцлогууд дээрээ дурын онцлогт суурилсан загвар (жишээлбэл, scikit-learn ангилагч эсвэл регрессор) байгуулж болно. *Урьдчилан сургасан гүн сургалтын жин* зөвхөн дээрх жагсаалтаар хязгаарлагдана.