

Duch maszyny

- **Limit czasu:** 10 minut
- **Wynik bazowy:** 28.6
- **Środowisko:** 1 GPU (≈16 GB VRAM), bez dostępu do internetu
- **Rozmiar rozwiązania:** `solution.ipynb` ≤ 20 MB
- **Pamięć masowa:** 5 GB
- **Modele pretrenowane:** wyłącznie [bge-base-en-v1.5](#) — **enkoder** tekstu (model osadzeń, ang. embedding model).

Zadanie

W Archiwum Narodowym Kazachstanu dzieją się dziwne rzeczy. Bibliotekarze twierdzą, że niektóre książki kończyły się kiedyś inaczej, ale nikt nie potrafi tego udowodnić — każdy egzemplarz jest taki sam, a każda historia nadal ma sens. Zaproszono Cię jako badacza AI, aby zlokalizować zmiany.



Fragment rozpoczyna się tekstem napisanym przez człowieka, a w pewnym momencie niepostrzeżenie przechodzi w kontynuację wygenerowaną przez model językowy. Czytany jako całość wygląda jak jeden spójny utwór — ale gdzieś w środku autor zmienia się z człowieka w maszynę. Twoim zadaniem jest **znalezienie tego przejścia: indeksu znaku, w którym kończy się część napisana przez człowieka, a zaczyna część wygenerowana przez maszynę**.

Każda próbka jest pojedynczym ciągiem znaków `text`. Istnieje dokładnie jedna granica. Wszystko przed nią zostało napisane przez człowieka; wszystko od niej począwszy zostało wygenerowane przez maszynę.

Zbiór danych

Angielskie fragmenty zwykłego tekstu (ang. plain-text), z jedną granicą w każdym z nich.

- **Część A** (przed granicą): fragment tekstu napisanego przez człowieka.
- **Część B** (od granicy): kontynuacja utworzona przez model językowy, uwarunkowana Częścią A.
- Każda część ma co najmniej 180 słów; łączna długość wynosi ~500–800 słów.
- `boundary_char_index` jest indeksem pierwszego znaku Części B: `text[boundary_char_index:]` jest częścią wygenerowaną przez maszynę, a `text[:boundary_char_index]` jest częścią napisaną przez człowieka, ten fragment zawiera także spację która odziela oba fragmenty.

Co otrzymujesz

Otrzymujesz **dwa foldery**:

Folder	Próbki	answers.jsonl?	Wykorzystanie
dataset/train/	1,221	□ dołączone	trenowanie / finetuning metody
dataset/test_public/	380	□ dołączone (kopia deweloperska)	uruchomienie pipeline'u i lokalne obliczenie własnego wyniku

Podczas **oceniania** Twój folder `dataset/test_public/` jest **zastępowany ukrytym zbiorem ewaluacyjnym**. Ma on ten sam format, ale **bez** `answers.jsonl`. Twój notebook jest na nim ponownie uruchamiany, a utworzony przez niego plik `answers.jsonl` jest oceniany.

- Publiczna tabela wyników korzysta z ukrytego zbioru **test_leaderboard_a** (380 próbek).
- Ostateczny ranking korzysta z ukrytego zbioru **test_leaderboard_b** (380 próbek).

Wszystkie trzy zbiory ewaluacyjne mają ten sam rozmiar i pochodzą z tego samego rozkładu co `train`, więc Twój lokalny wynik dla `dataset/test_public/` stanowi rozsądne oszacowanie wyniku w tabeli wyników.

Format na dysku

```
dataset/train/data.jsonl      # w każdej linii znajduje się jeden obiekt JSON: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # tylko w kopii deweloperskiej — BRAK w ukrytym zbiorze służącym do oceny
```

- Identyfikatory w `answers.jsonl` odpowiadają identyfikatorom w `data.jsonl`.
- `dataset/train/` (z odpowiedziami) jest dostępny zawsze, gdy trenujesz lub dostrajasz model.

Wyjście (format zgłoszenia)

Przesyłasz **pojedynczy notebook, który musi nosić nazwę `solution.ipynb`**. Ta dokładna nazwa pliku jest wymagana. Wszystkie inne pliki zostaną odrzucone bez uruchamiania.

Twój notebook musi **odczytać** `dataset/test_public/data.jsonl` i zapisać pojedynczy plik `answers.jsonl` w katalogu głównym repozytorium — po jednym obiekcie JSON w każdym wierszu, odwzorowującym identyfikator każdej próbki na przewidziany przez Ciebie indeks granicznego znaku:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` musi być **liczbą całkowitą należącą do przedziału $[0, \text{len}(\text{text})]$** .
- Każdy identyfikator w `dataset/test_public/data.jsonl` powinien wystąpić dokładnie raz. Próbką, której brakuje w `answers.jsonl` (albo której wartość nie jest liczbą całkowitą / wykracza poza zakres), otrzymuje 0 punktów za tę próbkę.

Ocenianie

Dla każdej próbki niech p będzie przewidzianym przez Ciebie indeksem, a t prawdziwą granicą. Wynik dla próbki maleje wykładniczo wraz z odległością wyrażoną w znakach:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Prowadzi to do następującego zachowania wyniku:

- **≈1.0** — dokładny znak granicy;
- **≈0.78** — błąd o 25 znaków;
- **≈0.61** — błąd o 50 znaków;
- **≈0.37** — błąd o 100 znaków;
- **≈0.01** — błąd o 500 znaków.

Wynik końcowy jest średnią wyników dla próbek ze wszystkich próbek w danym podzbiore (podawaną w skali 0–100). Metryka nagradza znalezienie się *blisko*, a nie tylko dokładne trafienie.

Ograniczenia

- **Środowisko:** jedno GPU (≈16 GB VRAM), bez dostępu do internetu podczas oceniania — dozwolony model (poniżej) jest już udostępniony. **Budżet czasu rzeczywistego: 10 minut** na całe uruchomienie — musi on obejmować wszelkie trenowanie / dostrajanie wykonywane podczas oceniania **oraz** inferencję na zbiorze ewaluacyjnym.
- **Dozwolony model pretrenowany** — poniższa jednoelementowa lista jest wyczerpująca; nie wolno używać żadnych innych wstępnie wytrenowanych wag. Jest on **z góry udostępniony w środowisku** (należy wczytać go w zwykły sposób, np. `from_pretrained`; podczas oceniania nie ma dostępu do internetu):
 - **bge-base-en-v1.5** — tekstowy **enkoder** mający 110M parametrów (model osadzeń). Tworzy on osadzenia (ang. embeddings) zdań/fragmentów; nie jest generatywnym modelem językowym. Możesz użyć go **bez zmian (zamrożone wagi) lub dostroić go na podzbiorze `train`** (pełne dostrajanie mieści się w budżecie 16 GB / 10 minut).
- Użycie narzędzi klasycznych / statystycznych nie jest ograniczone: możesz zbudować dowolny model oparty na cechach (ang. feature-based model) (np. klasyfikatory lub regresory scikit-learn) na podstawie samodzielnie obliczonych cech osadzeń. *Wagi pretrenowanych modeli głębokich* są ograniczone wyłącznie do powyższej listy.