

Призрак машины

- **Ограничение по времени:** 10 минут
- **Бейзлайн-результат:** 28.6
- **Среда:** один GPU (≈16 GB VRAM), без доступа к интернету
- **Размер решения:** `solution.ipynb` ≤ 20 MB
- **Хранилище:** 5 GB
- **Предобученные модели:** только [bge-base-en-v1.5](#) — текстовый **энкодер** (модель эмбедингов).

Задача

В Национальном архиве Казахстана происходят странные вещи. Библиотекари утверждают, что раньше некоторые книги заканчивались иначе, но никто не может этого доказать — все экземпляры одинаковы, и каждый рассказ по-прежнему имеет смысл. Вас пригласили в качестве исследователя ИИ, чтобы найти изменения.



Отрывок начинается как текст, написанный человеком, а затем в некоторый момент незаметно переходит в продолжение, сгенерированное языковой моделью. При прочтении целиком он выглядит как единый связный текст, но где-то в середине автор меняется с человека на машину. Ваша задача — **найти этот переход: индекс символа, на котором заканчивается написанная человеком часть и начинается машинная часть**.

Каждый пример представляет собой одну строку `text`. Существует ровно одна граница. Всё, что находится до неё, написано человеком; всё, начиная с неё, сгенерировано машиной.

Датасет

Англоязычные отрывки в виде обычного текста, по одной границе в каждом.

- **Часть А** (до границы): фрагмент текста, написанного человеком.
- **Часть В** (начиная с границы): продолжение, созданное языковой моделью, основанное на Части А.
- Каждая часть содержит не менее 180 слов; общая длина составляет ~500–800 слов.
- **boundary_char_index** — это индекс первого символа Части В: `text[:boundary_char_index]` — часть, написанная человеком, а `text[boundary_char_index:].lstrip()` — машинная часть вместе с пробелом, который отделяет две части.

Что у вас есть

У вас есть **две папки**:

Папка	Кол-во примеров	есть ли <code>answers.jsonl</code>	как использовать
<code>dataset/train/</code>	1,221	☐ включены	обучение / дообучение вашего метода
<code>dataset/test_public/</code>	380	☐ включены (валидационная копия)	запуск вашего пайплайна и самостоятельная локальная оценка

Во время проверки ваша папка `dataset/test_public/` **заменяется скрытым оценочным набором**. Он имеет тот же формат, но **без `answers.jsonl`**. Ваш ноутбук запускается на нём повторно, и оценивается созданный им `answers.jsonl`.

- Для public leaderboard используется скрытый набор **test_leaderboard_a** (380 примеров).
- Для private leaderboard используется скрытый набор **test_leaderboard_b** (380 примеров).

Все три оценочных набора имеют одинаковый размер и взяты из того же распределения, что и `train`, поэтому ваша локальная оценка `dataset/test_public/` является разумной оценкой вашего результата на лидерборде.

Формат на диске

```
dataset/train/data.jsonl      # каждая строка — один объект JSON: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # валидационная часть. Этого НЕТ в тестовых данных, на которых тестирует сист
```

- Идентификаторы в `answers.jsonl` соответствуют идентификаторам в `data.jsonl`.
- `dataset/train/` (с ответами) доступен всегда, когда вы обучаете или дообучаете модель.

Вывод (формат посылки)

Вы отправляете **один ноутбук, который должен называться `solution.ipynb`**. Имя файла должно быть ровно такое. Всё остальное отклоняется без запуска.

Ваш ноутбук должен **прочитать `dataset/test_public/data.jsonl`** и записать один файл **`answers.jsonl`** в корне репозитория — по одному объекту JSON в каждой строке, сопоставляя идентификатор каждого примера с предсказанным вами индексом символа границы:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` должен быть **целым числом в `[0, len(text)]`**.
- Каждый идентификатор из `dataset/test_public/data.jsonl` должен встречаться ровно один раз. Пример, отсутствующий в `answers.jsonl` (либо имеющий нецелое значение / значение вне допустимого диапазона), получает 0 баллов за этот пример.

Оценивание

Для каждого примера пусть p — предсказанный вами индекс, а t — истинная граница. Оценка за пример экспоненциально убывает с увеличением расстояния в символах:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Это приводит к следующему поведению оценки:

- **≈1.0** — точный символ границы;
- **≈0.78** — ошибка на 25 символов; **≈0.61** — ошибка на 50 символов;
- **≈0.37** — ошибка на 100 символов;
- **≈0.01** — ошибка на 500 символов.

Итоговая оценка представляет собой среднее значение оценок за все примеры в выборке (представленное по шкале 0–100). Метрика поощряет близость к границе, а не только точное совпадение.

Ограничения

- **Среда:** один GPU (≈16 GB VRAM), без доступа к интернету во время проверки — разрешённая модель (указанная ниже) уже предоставлена. **Ограничение по реальному времени: 10 минут** на весь запуск — сюда должны входить любое обучение / дообучение, выполняемое вами во время проверки, **а также** инференс на тестовом наборе.
- **Разрешённая предобученная модель** — только то, что дано, никакие другие предобученные веса использовать нельзя. Модель **заранее предоставлена в среде** (загрузите её обычным способом, например, `from_pretrained`; во время проверки доступа к

интернету нет):

- **bge-base-en-v1.5** — текстовый **энкодер** (эмбеддер) со 110M параметров. Он создаёт эмбединги предложений/отрывков; это не генеративная языковая модель. Вы можете использовать его **как есть (с замороженными весами) или дообучить на выборке train** (полное дообучение должно укладываться в ограничения 16 GB / 10 минут).
- Классические / статистические инструменты не ограничены: вы можете построить любую модель на основе признаков (например, классификаторы или регрессоры scikit-learn) поверх самостоятельно вычисленных фичей. Ограничение на "разрешенные предобученные модели" распространяется на *предобученные веса моделей глубокого обучения*.