

Duch stroja

- **Časový limit:** 10 minút
- **Baseline skóre:** 28.6
- **Prostredie:** jedna GPU (≈16 GB VRAM), bez internetu
- **Veľkosť riešenia:** `solution.ipynb` ≤ 20 MB
- **Úložisko:** 5 GB
- **Predtrénované modely:** iba [bge-base-en-v1.5](#) — textový **enkóder** (embeddingový model).

Úloha

V Národnom archíve Kazachstanu sa dejú zvláštne veci. Knihovníci tvrdia, že niektoré knihy sa kedysi končili inak, ale nikto to nedokáže preukázať — každý výtlačok je rovnaký a každý príbeh stále dáva zmysel. Ako výskumník v oblasti AI ste pozvaný, aby ste našli zmeny.



Pasáž sa začína ako text napísaný človekom a v istom bode nepozorovane prejde na pokračovanie vygenerované jazykovým modelom. Keď sa číta ako celok, pôsobí ako jeden súvislý text — niekde uprostred sa však autor zmení z človeka na stroj. Vašou úlohou je **nájsť tento prechod: index znaku, na ktorom sa končí ľudská časť a začína strojová časť**.

Každá vzorka je jeden reťazec `text`. Existuje presne jedna hranica. Všetko pred ňou je vytvorené človekom; všetko od nej ďalej je vygenerované strojom.

Dataset

Anglické pasáže vo formáte obyčajného textu, každá s jednou hranicou.

- **Časť A** (pred hranicou): úryvok textu napísaného človekom.
- **Časť B** (od hranice ďalej): pokračovanie vytvorené jazykovým modelom, vytvorené na základe časti A.
- Každá časť má aspoň 180 slov; celková dĺžka je ~500–800 slov.
- **boundary_char_index** je index **prvého znaku časti B**: `text[:boundary_char_index]` je ľudská časť spolu s jedinou medzerou oddeľujúcou obe časti a `text[boundary_char_index:]` je strojová časť.

Čo dostanete

Dostanete **dva priečinky**:

Priečinok	Vzorky	answers.jsonl?	Použite ho na
dataset/train/	1,221	☐ zahrnuté	trénovanie/doladenie vašej metódy
dataset/test_public/	380	☐ zahrnuté (vývojová kópia)	spustenie vášho postupu a lokálne vyhodnotenie vlastného skóre

Počas **hodnotenia** sa váš priečinok `dataset/test_public/` **nahradí skrytou vyhodnocovacou množinou**. Má rovnaký formát, ale je **bez answers.jsonl**. Váš notebook sa na nej znova spustí a výstup `answers.jsonl`, ktorý vytvorí, sa vyhodnotí.

- Verejný rebríček používa skrytú množinu **test_leaderboard_a** (380 vzoriek).
- Konečné poradie používa skrytú množinu **test_leaderboard_b** (380 vzoriek).

Všetky tri vyhodnocovacie množiny majú rovnakú veľkosť a pochádzajú z rovnakého rozdelenia ako `train`, takže vaše lokálne skóre `dataset/test_public/` je rozumným odhadom vášho skóre v rebríčku.

Formát na disku

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only – ABSENT in the hidden grading set
```

- ID v `answers.jsonl` zodpovedajú ID v `data.jsonl`.
- `dataset/train/` (s odpoveďami) je k dispozícii vždy, keď trénujete alebo doladujete.

Výstup (formát odovzdania)

Odozdávate **jeden notebook, ktorý musí mať názov solution.ipynb**. Tento presný názov súboru je povinný. Akýkoľvek iný názov bude zamietnutý bez spustenia.

Váš notebook musí **načítať** `dataset/test_public/data.jsonl` a zapísať jeden súbor `answers.jsonl` do koreňového adresára repozitára — jeden objekt JSON na riadok, ktorý mapuje ID každej vzorky na vami predpovedaný index znaku hranice:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` musí byť **celé číslo z rozsahu `[0, len(text)]`**.

- Každé ID v `dataset/test_public/data.jsonl` by sa malo objaviť práve raz. Vzorka, ktorá chýba v `answers.jsonl` (alebo má neceločíselnú hodnotu/hodnotu mimo rozsahu), získa 0 bodov za danú vzorku.

Hodnotenie

Pre každú vzorku nech p označuje vami predpovedaný index a t skutočnú hranicu. Skóre za vzorku klesá exponenciálne so vzdialenosťou v znakoch:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

To vedie k nasledujúcemu správaniu skóre:

- **≈1.0** — presný znak hranice;
- **≈0.78** — odchýlka 25 znakov;
- **≈0.61** — odchýlka 50 znakov;
- **≈0.37** — odchýlka 100 znakov;
- **≈0.01** — odchýlka 500 znakov.

Konečné skóre je priemerom skóre za jednotlivé vzorky zo všetkých vzoriek v danej časti (uvádza sa na stupnici 0–100). Metrika odmeňuje priblíženie sa, nielen presnosť.

Obmedzenia

- **Prostredie:** jedna GPU (≈16 GB VRAM), počas hodnotenia bez internetu — povolený model (uvedený nižšie) je už poskytnutý. **Časový limit reálneho času: 10 minút** na celé spustenie — musí zahŕňať akékoľvek tréningovanie/dolaďovanie, ktoré vykonáte počas hodnotenia, **vrátane** inferencie na vyhodnocovacej množine.
- **Povolený predtrénovaný model** — tento zoznam je úplný; nemožno použiť žiadne iné predtrénované váhy. Model je **vopred poskytnutý v prostredí** (načítajte ho bežným spôsobom, napr. `from_pretrained`; počas hodnotenia nie je k dispozícii internet):
 - **bge-base-en-v1.5** — textový **enkóder** so 110M parametrami (embeddingový model). Vytvára embeddingy viet/pasáží; nie je to generatívny jazykový model. Môžete ho použiť **v pôvodnom stave (so zmrazenými príznakmi) alebo ho doladiť na časti train** (úplné doladenie sa zmestí do limitu 16 GB / 10 minút).
- Klasické/štatistické nástroje nie sú obmedzené: nad embeddingovými príznakmi, ktoré si sami vypočítate, môžete vytvoriť ľubovoľný model založený na príznakoch (napr. klasifikátory alebo regresory scikit-learn). *Predtrénované váhy hlbokého učenia* sú obmedzené iba na zoznam uvedený vyššie.