

기계의 유령

- 시간: 10분
- 베이스라인 점수: 28.6
- 환경: GPU 1대(≈16 GB VRAM), 인터넷 없음
- 솔루션 크기: `solution.ipynb` ≤ 20 MB
- 공간: 5 GB
- 사전학습 모델: [bge-base-en-v1.5](#) 만 사용 가능, 텍스트 **encoder**(임베딩 모델).

과제

카자흐스탄 국립 기록보관소에서 사서들 왈 일부 책의 결말이 예전에는 달랐다고 말하는데 아무도 입증 불가능함, 모든 사본이 동일, 모든 이야기가 말이 되기 때문임. 그러한 변경점을 찾아내야함



하나의 지문은 사람이 쓴 텍스트로 시작, 어느 시점에서 조용히 언어 모델이 생성한 내용으로 전환됨. 전체 읽으면 일관된 글처럼 보이지만, 중간 어딘가에서 저자가 사람에서 기계로 바뀜. 과제는 **전환 지점, 즉 사람이 쓴 부분이 끝나고 기계가 쓴 부분이 시작되는 문자 인덱스를 찾는 것**.

각 샘플은 하나의 문자열 `text` 임. 경계는 단 하나만 존재. 그 앞의 모든 내용은 사람이 썼으며 그 지점부터의 모든 내용은 기계가 생성했음

데이터셋

일반 텍스트 형식의 영어 지문이며, 각각 경계가 하나씩 존재함

- **Part A**(경계 이전): 사람이 쓴 텍스트
- **Part B**(경계 이후): Part A 이후 언어 모델이 생성한 텍스트

- 각 부분은 최소 180 단어, 전체 길이는 약 500~800 단어
- **boundary_char_index** 는 Part A가 끝나는 문자 오프셋임 `text[:boundary_char_index]` 은 사람이 쓴 부분 `text[boundary_char_index:].lstrip()` 는 기계가 쓴 부분

제공되는 것

두 개의 폴더를 받음:

폴더	샘플 수	answers.jsonl?	용도
dataset/train/	1,221	☒ 포함	방법을 학습 / 파인튜닝
dataset/test_public/	380	☒ 포함 (dev 사본)	파이프라인을 실행하고 로컬에서 자체 채점

채점 시점에는 dataset/test_public/ 폴더가 **숨겨진 평가 세트로 교체됨**. 형식은 동일하지만 **answers.jsonl** 는 **없음**. 노트북이 그 위에서 다시 실행됨, 노트북이 생성한 answers.jsonl 이 채점됨

- 공개 리더보드는 숨겨진 **test_leaderboard_a** 세트(380 샘플)를 사용
- 최종 순위는 숨겨진 **test_leaderboard_b** 세트(380 샘플)를 사용

세 평가 세트는 모두 크기가 같고 train 과 동일한 분포에서 추출되었음, 로컬 dataset/test_public/ 점수는 리더보드 점수에 대한 합리적 추정치로 쓸 수 있음

디스크 상의 형식

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only - ABSENT in the hidden grading set
```

- answers.jsonl 의 id는 data.jsonl 의 id와 일치함
- dataset/train/ (정답 포함)은 학습이나 파인튜닝을 할 때 언제든지 사용 가능

출력 (제출 형식)

노트북 파일 하나를 제출, 이름은 반드시 solution.ipynb 이어야함. 정확한 파일 이름이 요구됨. 그 외의 것은 거부됨

여러분의 노트북은 **dataset/test_public/data.jsonl** 을 읽고, 저장소 루트에 단일 파일 **answers.jsonl** 을 작성해야 함 한 줄에 하나의 JSON 객체로, 각 샘플 id를 여러분이 예측한 경계 문자 인덱스에 매핑함

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- boundary_char_index 는 `[0, len(text)]` 범위의 정수여야함
- dataset/test_public/data.jsonl 의 모든 id는 정확히 한 번씩 나타나야 함. answers.jsonl 에서 누락된 샘플 (또는 정수가 아니거나 범위 벗어난 값을 가진 샘플)은 해당 샘플에 대해 0점을 받음

채점

각 샘플에 대해 p 를 여러분의 예측 인덱스, t 를 실제 경계라고 할 시, 샘플별 점수는 문자 거리에 따라 지수적으로 감소함:

$$\text{score} = \exp\left(-\frac{|p-t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

따라서 점수는 다음과 같음:

- **=1.0** — 경계 문자를 정확히 맞춘 경우;
- **≈0.78** — 25 문자 차이; **≈0.61** — 50 문자 차이;
- **≈0.37** — 100 문자 차이;
- **≈0.01** — 500 문자 차이.

최종 점수는 해당 분할의 모든 샘플에 대한 샘플별 점수의 **평균**임 (0-100 스케일임). 따라서 *가깝게* 맞는 것도 점수 줌

제약 조건

- **환경:** GPU 1대(≈16 GB VRAM), 채점 시점에 인터넷 없음, 허용된 모델(아래)은 이미 제공되어 있습니다. **실제 소요 시간 예산: 전체 실행에 10분** — 이 시간 안에 수행하는 모든 학습 / 파인튜닝 및 평가 세트에 대한 추론이 모두 포함되어야 함
- **허용된 사전학습 모델** — 이 목록이 전부이며, 그 외의 사전학습 가중치는 사용 불가. 해당 모델은 **환경에 미리 제공되어 있음** (평소처럼 로드하십시오, 예: `from_pretrained`; 채점 시점에는 인터넷이 없습니다):
 - **bge-base-en-v1.5** — 파라미터 1억 1천만 개(110M)의 텍스트 **encoder**(임베딩 모델). 이 모델은 문장/지문 임베딩을 생성하며, 생성형 언어 모델이 아님. 이 모델을 **그대로(고정된 피쳐로) 사용하거나 train 분할에서 파인튜닝**할 수 있음 (전체 파인튜닝은 16 GB / 10분 에 들어감).
- 고전적 / 통계적 도구는 제한 없음 : 여러분이 직접 계산한 임베딩 피쳐 위에 임의의 피쳐 기반 모델(예: scikit-learn 분류기 또는 회귀기)을 구축 가능함 **사전학습된 딥러닝 가중치**만 위 목록으로 제한됨