

Привид машини

- **Обмеження часу:** 10 хвилин
- **Базова оцінка:** 28.6
- **Середовище:** один GPU (≈ 16 GB VRAM), без доступу до інтернету
- **Розмір розв'язку:** `solution.ipynb` ≤ 20 MB
- **Сховище:** 5 GB
- **Попередньо навчені моделі:** лише [bge-base-en-v1.5](#) — текстовий **енкодер** (модель векторних представлень).

Завдання

У Національному архіві Казахстану відбуваються дивні речі. Бібліотекарі кажуть, що раніше деякі книги закінчувалися інакше, але ніхто не може цього довести — усі примірники однакові, і кожна історія досі має сенс. Вас запросили як дослідника ШІ, щоб знайти зміни.



Уривок починається як текст, написаний людиною, а в певний момент непомітно переходить у продовження, згенероване мовною моделлю. Якщо читати його як єдине ціле, він виглядає як один зв'язний текст — але десь посередині автор змінюється з людини на машину. Ваше завдання — **знайти цей перехід**: індекс символу, на якому закінчується частина, написана людиною, і починається частина, написана машиною.

Кожен зразок є одним рядком `text`. Існує рівно одна межа. Усе до неї написане людиною; усе від неї й далі згенероване машиною.

Набір даних

Англомовні уривки у форматі звичайного тексту, по одній межі в кожному.

- **Частина А** (до межі): уривок тексту, написаного людиною.
- **Частина В** (від межі й далі): продовження, створене мовною моделлю за умови Частини А.
- Кожна частина містить щонайменше 180 слів; загальна довжина становить ~500–800 слів.
- **boundary_char_index** — це зсув у символах, на якому закінчується Частина А: `text[:boundary_char_index]` є частиною, написаною людиною, а `text[boundary_char_index:].lstrip()` є частиною, написаною машиною.

Що ви отримуєте

Ви отримуєте **дві папки**:

Папка	Зразки	answers.jsonl?	Використання
dataset/train/	1,221	□ включено	навчання / донавчання вашого методу
dataset/test_public/	380	□ включено (копія для розробки)	запуск вашого конвеєра та локальне самостійне оцінювання

Під час **оцінювання** вашу папку `dataset/test_public/` **заміняють прихованим оцінювальним набором**. Він має такий самий формат, але **без answers.jsonl**. Ваш ноутбук повторно запускають на ньому, а створений ним `answers.jsonl` оцінюють.

- Для публічної рейтингової таблиці використовується прихований набір **test_leaderboard_a** (380 зразків).
- Для остаточного рейтингу використовується прихований набір **test_leaderboard_b** (380 зразків).

Усі три оцінювальні набори мають однаковий розмір і походять із того самого розподілу, що й `train`, тому ваша локальна оцінка `dataset/test_public/` є прийнятною оцінкою вашого результату в рейтинговій таблиці.

Формат на диску

```
dataset/train/data.jsonl      # one JSON object per line: {"id": "...", "text": "..."}
dataset/train/answers.jsonl  # {"id": "...", "boundary_char_index": 1842}
dataset/test_public/data.jsonl      # {"id": "...", "text": "..."}
dataset/test_public/answers.jsonl  # dev copy only — ABSENT in the hidden grading set
```

- Ідентифікатори в `answers.jsonl` відповідають ідентифікаторам у `data.jsonl`.
- `dataset/train/` (з відповідями) доступний щоразу, коли ви навчаєте або донавчаєте модель.

Вихідні дані (формат подання)

Ви подаєте **один ноутбук, який повинен мати назву solution.ipynb**. Ця точна назва файлу є обов'язковою. Усе інше буде відхилено без запуску.

Ваш ноутбук повинен **зчитати** `dataset/test_public/data.jsonl` і записати один файл `answers.jsonl` у кореневому каталозі репозиторію — по одному об'єкту JSON у кожному рядку, що зіставляє ідентифікатор кожного зразка з передбаченим вами індексом символу межі:

```
{"id": "example_000123", "boundary_char_index": 1790}
{"id": "example_000124", "boundary_char_index": 2450}
```

- `boundary_char_index` має бути **цілим числом у $[0, \text{len}(\text{text})]$** .
- Кожен ідентифікатор із `dataset/test_public/data.jsonl` повинен з'явитися рівно один раз. Зразок, відсутній у `answers.jsonl` (або з нецілим значенням / значенням поза допустимим діапазоном), отримує 0 балів за цей зразок.

Оцінювання

Для кожного зразка нехай p — передбачений вами індекс, а t — справжня межа. Оцінка за зразок експоненційно зменшується зі збільшенням відстані в символах:

$$\text{score} = \exp\left(-\frac{|p - t|}{\tau}\right) \in (0, 1], \text{ where } \tau = 100.$$

Це зумовлює таку поведінку оцінки:

- **≈1.0** — точний символ межі;
- **≈0.78** — похибка 25 символів; **≈0.61** — похибка 50 символів;
- **≈0.37** — похибка 100 символів;
- **≈0.01** — похибка 500 символів.

Підсумкова оцінка є середнім значенням оцінок за всі зразки у вибірці (подається за шкалою 0–100). Метрика винагороджує наближення до межі, а не лише точне визначення.

Обмеження

- **Середовище:** один GPU (≈16 GB VRAM), без доступу до інтернету під час оцінювання — дозволена модель (нижче) вже надана. **Бюджет реального часу: 10 хвилин** на весь запуск — він має охоплювати будь-яке навчання / донавчання, яке ви виконуєте під час оцінювання, **а також** інференс на оцінювальному наборі.
- **Дозволена попередньо навчена модель** — цей перелік є вичерпним; жодні інші попередньо навчені ваги використовувати не можна. Вона **заздалегідь надана в середовищі** (завантажуйте її звичайним способом, наприклад `from_pretrained`; під час оцінювання доступу до інтернету немає):
 - **bge-base-en-v1.5** — текстовий **енкодер** зі 110M параметрів (модель векторних представлень). Він створює векторні представлення речень/уривків; це не генеративна мовна модель. Ви можете використовувати його **без змін (із замороженими ознаками) або донавчити на вибірці train** (повне донавчання вкладається в бюджет 16 GB / 10 хвилин).
- Класичні / статистичні інструменти не обмежуються: ви можете побудувати будь-яку модель на основі ознак (наприклад, класифікатори або регресори `scikit-learn`) поверх ознак векторних представлень, які ви обчислюєте самостійно. Обмеження щодо *попередньо навчених ваг глибокого навчання* стосуються лише наведеного вище переліку.